



Universidad
Nacional
de Loja

Universidad Nacional de Loja

Facultad de la Energía, las Industrias y los Recursos Naturales
No Renovables

Carrera de Computación

APE 3: Taller de Formulación de Preguntas y
Objetivos (SMART).

APE 3: Workshop on Formulating Questions and
Objectives (SMART).

Metodología de la Investigación en
Computación.

AUTOR:

Jaime Alejandro Landázuri Román

TUTOR:

Prof. Luis Chamba-Eras

Loja, Ecuador

2026

Declaración de uso de IA Generativa

Yo, **Jaime Landázuri**, en calidad de autor, declaro de manera transparente y responsable el uso de herramientas de Inteligencia Artificial Generativa (IAG) durante el desarrollo del presente trabajo, en conformidad con los principios de integridad académica, ética investigativa y buenas prácticas en el uso de tecnologías emergentes.

1. Alcance del uso de IA generativa

El uso de herramientas de IAG se ha limitado a funciones de apoyo, sin sustituir el juicio crítico ni la autoría intelectual del autor. En particular, se han utilizado para:

- Mejora de redacción y estilo académico.
- Generación de ideas preliminares.
- Apoyo en la estructuración del documento.
- Asistencia en traducción técnica.

2. Clasificación del uso según GAIDeT

De acuerdo con la taxonomía GAIDeT, el uso de IA generativa en este trabajo se clasifica en:

- **Nivel 1 – Asistencia Lingüística:** Corrección gramatical y mejora de claridad.
- **Nivel 2 – Apoyo en Ideación:** Generación de ideas y esquemas conceptuales.
- **Nivel 3 – Asistencia Técnica:** Apoyo en generación de código y explicaciones técnicas.

No se ha utilizado IA generativa para la generación autónoma de resultados ni para sustituir el análisis crítico del autor.

3. Validación y responsabilidad

Todo contenido asistido por IA ha sido revisado, validado y adaptado por el autor, quien asume la responsabilidad total sobre la calidad, veracidad y originalidad del trabajo.

4. Herramientas utilizadas

Se emplearon modelos de lenguaje (LLMs) y herramientas de asistencia técnica para redacción, estructuración y apoyo conceptual.

5. Consideraciones éticas

El uso de IA se realizó respetando principios de honestidad académica, normativas institucionales de la Universidad Nacional de Loja y buenas prácticas internacionales.

6. Declaración final

Declaro que el uso de IA generativa ha sido ético, transparente y complementario, sin comprometer la autoría ni la integridad académica del presente trabajo.

Loja, Ecuador, [Fecha]

[Nombre del Estudiante]

Autor

Índice General

Declaración de uso de IA Generativa	I
1 Introducción	IV
1.1 Tabla de clasificación metodológica	IV
1.2 Preguntas de Investigación y Objetivos	VII
1.2.1 1. Objetivos: Mutación Adaptativa en PSO (PI1) [1]	VIII
1.2.2 2. Objetivos: Hibridación PSO-GWO (PI2) [2]	VIII
1.2.3 3. Objetivos: Algoritmo de Mariposa y Hill Climbing (PI3) [3] .	VIII
1.2.4 4. Objetivos: Pesos Adaptativos en WOA (PI4) [4]	IX
1.3 Antecedentes	IX
1.4 Estado del Arte y Trabajos Relacionados	X
1.4.1 Mejoras Metodológicas e Hibridaciones	X
1.4.2 Aplicaciones Prácticas en Ingeniería	X
1.5 Artículos No Relevantes	XI
Referencias bibliográficas	XVII

1. Introducción

Este trabajo se desarrolla en el marco del Taller de Formulación de Preguntas y Objetivos, enfocándose en la optimización de algoritmos metaheurísticos. A continuación, se detallan las interrogantes que guían esta investigación y sus respectivos objetivos, fundamentados en el estado del arte actual [1–5].

1.1. Tabla de clasificación metodológica

Cuadro 1.1: Clasificación Metodológica y Observaciones Técnicas de la Literatura

Trabajo	Cuant.	Cual.	Mixto	Observación
[6]	X			Midieron media, desviación estándar, mejor y peor valor de la función de costo y tiempo; el PSO clásico obtuvo una peor media (0,4304) frente a la variante propuesta mEAO (0,4040).
[7]	X			Evaluaron el error de seguimiento de estado estable, tiempo de cálculo y número de evaluaciones; PSO obtuvo el menor error ($7,36 \times 10^{-5}$ rad) en 23,44 s usando 1500 evaluaciones.
[3]	X			Midieron la puntuación de la función de fitness en reducción de características; PSO igualó el rendimiento del optimizador propuesto (DBOA) obteniendo alta calidad en 4 datasets (Australian, Spambase, CTG y M-of-N).
[5]	X			Midieron los valores de diseño (media, mejor, peor, desviación) en problemas de ingeniería con restricciones; PSO estándar obtuvo un peso óptimo de 1,820395 en diseño de vigas soldadas.

Continúa en la siguiente página...

Cuadro 1.1 – Continuación de la página anterior

Trabajo	Cuant.	Cual.	Mixto	Observación
[4]	X			Evaluaron métricas de costo óptimo sobre múltiples iteraciones; el algoritmo mutado propuesto (NAWM-WOA) logró un peso de 1,724852 superando al PSO base (1,820395) en diseño de armaduras.
[8]	X			Midieron la convergencia y el factor de daño (<i>skin factor</i>) post-acidificación en pozos petroleros; PSO mostró una convergencia inicial rápida y eficiente, siendo computacionalmente más ágil que los algoritmos genéticos (GA).
[9]	X			Midieron tiempo de convergencia, precisión de seguimiento de actitud y sobreimpulso; el controlador optimizado por PSO redujo el tiempo de convergencia un 35 % y mejoró la precisión de la trayectoria un 40 %.
[10]	X			Evaluaron Error Absoluto Integral (IAE), tiempo de asentamiento y sobreimpulso; PSO logró estabilizarse en 5,90 s con un sobreimpulso de 1,79°, siendo más robusto que GWO pero más lento que WOA.
[11]	X			Midieron tiempo de convergencia, magnitud pico, duración pico y error EMG-RMS; PSO presentó una alta sensibilidad a la perturbación de hiperparámetros (hasta ≈ 56 % de error en la duración).
[12]	X			Midieron el tiempo de subida, tiempo de asentamiento, sobreimpulso y Error en Estado Estable (SSE); el sintonizador MRAC-PSO ajustó las articulaciones de cadera y rodilla equilibrando el tiempo de respuesta y precisión.
[12]	X			Evaluaron el costo computacional fuera de línea en modelos robóticos; la optimización de parámetros vía PSO mejoró radicalmente el seguimiento de la trayectoria frente a la sintonización clásica de Ziegler-Nichols (Z-N).

Continúa en la siguiente página...

Cuadro 1.1 – Continuación de la página anterior

Trabajo	Cuant.	Cual.	Mixto	Observación
[13]	X			Midieron el Error Cuadrático Integral (ISE) para resolver problemas multiobjetivo en un péndulo invertido; utilizaron la actualización matemática de velocidad y posiciones clásicas del enjambre (PSO).
[14]	X			Evaluaron el costo (ITAE+ISO) frente a iteraciones en sistemas no lineales; la hibridación PSO-GWO requirió menos del 10 % de evaluaciones de la función de costo que un PSO independiente para converger.
[15]	X			Midieron deformación, reducción de peso y costo de material en diseño de edificios de múltiples pisos; se utilizó MOPSO para generar frentes de Pareto óptimos balanceando el uso de materiales con la rigidez estructural.
[16]		X		Analizaron tasas de publicación, topologías e hibridaciones; revisión exhaustiva que documenta la evolución matemática del PSO clásico, señalando su propensión a la convergencia prematura en espacios multimodales.
[17]	X			Midieron la curvatura máxima y tensión efectiva en cables submarinos dinámicos; el algoritmo de PSO iteró descartando configuraciones inviables para converger hacia los parámetros óptimos del diseño.
[18]		X		Evaluaron precisión, reducción de características y tiempo en múltiples benchmarks; la encuesta documenta que PSO alcanzó un 96,5 % de precisión en predicción médica y mostró menores tiempos computacionales frente a ACO/SA.
[19]		X		Analizaron el control de los hiperparámetros (inercia, factores cognitivos) y variantes binarias; se destaca la dificultad para afinar estos parámetros sin caer en estancamientos cerca del óptimo global.

Continúa en la siguiente página...

Cuadro 1.1 – Continuación de la página anterior

Trabajo	Cuant.	Cual.	Mixto	Observación
[20]	X			Midieron el error posicional, orientación, suavidad (CJV) y tasa de éxito (TSR) en brazos quirúrgicos; el esquema híbrido RS-PSO superó al PSO base con un error posicional de alta precisión ($1,8 \times 10^{-5}$ m).
[2]	X			Midieron puntajes promedio, mejores y peores de la función de diseño; el PSO clásico promedió un rango de 1,8–2,8, mientras que el modelo híbrido (TPOP-SOGWO) logró rango 1,0 (óptimo).
[1]	X			Midieron los valores óptimos (mejor, peor, medio) de la función de costo versus iteraciones; la variante mutada (ACPSO) logró un menor costo computacional en menos iteraciones que el modelo Crazy PSO clásico.

1.2. Preguntas de Investigación y Objetivos

Cuadro 1.2: Clasificación de las Preguntas de Investigación

Tipo de Investigación	Pregunta de Investigación
Exploratoria	PI1. ¿Cómo optimiza PSO problemas complejos en ingeniería? [1].
Descriptiva	PI2. ¿Cuál es el nivel de la tasa de convergencia respecto al equilibrio entre exploración y explotación de los algoritmos híbridos de enjambre (específicamente TPOPSOGWO) en problemas reales de diseño de ingeniería? [2].
Aplicada	PI3. ¿Cómo se puede mejorar la eficiencia del diseño estructural de vigas soldadas usando la técnica de inicialización de Aprendizaje Basado en la Oposición (OBL)? [2].
Experimental	PI4. ¿Cuál es el impacto de incorporar la mutación adaptativa (ACPSO) en la tasa de convergencia y el costo computacional frente al modelo base "Crazy PSO" (CPSO)? [1].

1.2.1. 1. Objetivos: Mutación Adaptativa en PSO (PI1) [1]

- **Objetivo General:** Evaluar el impacto de incorporar la estrategia de mutación adaptativa (ACPSO) en la tasa de convergencia y el costo computacional en comparación con el algoritmo base Crazy PSO.
- **Objetivos Específicos:**
 - **A nivel exploratorio:** Identificar la pérdida de precisión en la fase de explotación y las causas de estancamiento del Crazy PSO frente a funciones matemáticas complejas.
 - **A nivel descriptivo:** Describir el comportamiento teórico de la mutación adaptativa en la actualización de la variable *Global_best* para evitar la convergencia prematura.
 - **A nivel aplicado:** Implementar el operador de mutación adaptativa en el entorno de desarrollo base del enjambre para refinar las soluciones.
 - **A nivel experimental:** Comparar los tiempos de ejecución y tasas de convergencia entre el CPSO y la variante ACPSO utilizando funciones Benchmark.

1.2.2. 2. Objetivos: Hibridación PSO-GWO (PI2) [2]

- **Objetivo General:** Determinar la eficiencia de la estrategia híbrida secuencial TPOP-SOGWO y el Aprendizaje Basado en la Oposición (OBL) en la minimización de costos.
- **Objetivos Específicos:**
 - **A nivel exploratorio:** Indagar sobre el desequilibrio estructural entre la exploración (GWO) y la explotación (PSO) en espacios de diseño de alta dimensionalidad.
 - **A nivel descriptivo:** Analizar el impacto métrico de la inicialización OBL en el mantenimiento de la diversidad poblacional.
 - **A nivel aplicado:** Modelar problemas de ingeniería sometidos a fuertes restricciones de tensión y capacidad (recipientes a presión, vigas soldadas).
 - **A nivel experimental:** Validar empíricamente la precisión matemática y el tiempo de cómputo del modelo híbrido frente a algoritmos tradicionales.

1.2.3. 3. Objetivos: Algoritmo de Mariposa y Hill Climbing (PI3) [3]

- **Objetivo General:** Evaluar la eficacia de integrar la técnica *Adaptive β -Hill Climbing* en el Algoritmo de Optimización de Mariposas (BOA).
- **Objetivos Específicos:**
 - **A nivel exploratorio:** Explorar la disminución de diversidad poblacional y la tendencia a caer en óptimos locales que presenta el algoritmo BOA convencional.

- **A nivel descriptivo:** Estudiar el impacto de las funciones de transferencia (S, U, V) para la conversión del espacio continuo a binario.
- **A nivel aplicado:** Desarrollar y configurar los operadores estocásticos (N -operator y β -operator) para la mejora de la descendencia.
- **A nivel experimental:** Medir la precisión de clasificación y la tasa de reducción de atributos en datasets estándar.

1.2.4. 4. Objetivos: Pesos Adaptativos en WOA (PI4) [4]

- **Objetivo General:** Analizar el rendimiento del algoritmo NAWMWOA mediante la integración de convergencia no lineal y pesos adaptativos.
- **Objetivos Específicos:**
 - **A nivel exploratorio:** Identificar las condiciones de estructura simple que provocan la convergencia prematura en el Algoritmo de la Ballena (WOA).
 - **A nivel descriptivo:** Definir formalmente el factor de convergencia no lineal y los parámetros de pesos adaptativos requeridos.
 - **A nivel aplicado:** Simular el comportamiento del algoritmo NAWMWOA en la resolución de restricciones en problemas de ingeniería reales.
 - **A nivel experimental:** Contrastar estadísticamente la velocidad de convergencia y la precisión del NAWMWOA contra el algoritmo original.

1.3. Antecedentes

La Optimización por Enjambre de Partículas (PSO), introducida originalmente por Kennedy y Eberhart en 1995, se ha consolidado como un pilar dentro de los algoritmos metaheurísticos inspirados en el comportamiento social de bandadas de aves y bancos de peces [19]. Para abordar problemas complejos en ingeniería, PSO modela las posibles soluciones como un conjunto de "partículas" que navegan a través de un espacio de búsqueda multidimensional. Cada partícula actualiza de forma iterativa su posición y velocidad basándose tanto en su experiencia histórica (óptimo personal) como en la información compartida por sus vecinos (óptimo global) [18]. La eficacia de PSO radica en su formulación matemática fundamental, la cual introduce conceptos clave como el peso de inercia y los coeficientes cognitivos y sociales para gestionar dinámicamente la transición de la fase de exploración (búsqueda global de nuevas regiones) a la de explotación (refinamiento local) [19]. Esta carencia de dependencia de la información del gradiente, sumada a su notable versatilidad topológica (por ejemplo, topologías de estrella o anillo), hace que PSO sea intrínsecamente capaz de optimizar espacios no lineales, ruidosos y de alta dimensionalidad característicos de la ingeniería moderna [18].

1.4. Estado del Arte y Trabajos Relacionados

Para superar las limitaciones inherentes del PSO clásico, como la convergencia prematura y el estancamiento en óptimos locales, la investigación reciente se ha centrado en hibridaciones avanzadas y la incorporación de mecanismos adaptativos, expandiendo significativamente su aplicabilidad en escenarios de ingeniería del mundo real.

1.4.1. Mejoras Metodológicas e Hibridaciones

Un avance notable en el estado del arte es el desarrollo de topologías híbridas, como el algoritmo Two-Phase Opposition-based PSO-GWO (TPOPSOGWO), el cual fusiona la capacidad de explotación de PSO con la exploración superior del Grey Wolf Optimizer (GWO) e integra aprendizaje basado en oposición para diversificar la población inicial y evitar mínimos locales [2]. De forma paralela, la literatura destaca el modelo "Crazy PSO", el cual ha sido mejorado mediante mutación adaptativa (ACPSO) introduciendo variables de "locura" que alteran estratégicamente las velocidades de las partículas para fomentar una exploración continua sin sacrificar la convergencia de la simulación [1]. Esta sinergia algorítmica también se observa en el diseño de controladores para sistemas fuertemente no lineales (como el oscilador de Duffing), donde la hibridación PSO-GWO ha demostrado reducir las evaluaciones de la función de costo a menos del 10 % respecto a métodos independientes, estabilizando la dinámica caótica de forma robusta [14]. Otra innovación reciente de alto impacto es la incorporación de la Teoría de Conjuntos Aproximados (Rough Sets) para formar el RS-PSO, un esquema que asigna dinámicamente hiperparámetros a las partículas según clases de equivalencia, logrando alta precisión sin recurrir a sintonizaciones computacionalmente prohibitivas [20].

1.4.2. Aplicaciones Prácticas en Ingeniería

La optimización basada en PSO es determinante en disciplinas donde los métodos analíticos tradicionales fracasan por la complejidad de las restricciones y variables continuas. En ingeniería aeroespacial, PSO ha demostrado ser instrumental para optimizar globalmente los parámetros de controladores de modo deslizante (NFTSMC), permitiendo la estabilización de actitud rápida y sin chattering en cohetes sujetos a fuertes perturbaciones aerodinámicas [9]. En el ámbito de la robótica y biomecatrónica, el algoritmo se utiliza con éxito tanto para el control de manipuladores articulares, minimizando los errores de seguimiento de trayectorias [7], como en la calibración de sistemas adaptativos de referencia (MRAC-PSO) aplicados a exoesqueletos para la rehabilitación de extremidades inferiores [12].

A un nivel de infraestructura y energía, la utilidad de PSO abarca la optimización de costos y materiales en el diseño estructural de edificios de múltiples pisos [15]. A su vez, en la ingeniería oceánica, PSO se implementa para minimizar curvaturas y tensiones máximas en el diseño de cables dinámicos para turbinas eólicas flotantes [17]. Además, su versatilidad se extiende a la ingeniería petrolera, donde recientes comparativas muestran la eficiencia de PSO en la calibración de variables de acidificación de pozos para la reducción del daño de formación

(skin factor) [8]. Finalmente, en un nivel computacional aplicado a la ingeniería de datos, PSO se emplea eficazmente en el ajuste de hiperparámetros de Redes Neuronales Convolucionales (CNN) para evitar el sobreajuste al procesar clasificaciones de suelos agrícolas [21].

1.5. Artículos No Relevantes

- **A Modified Enzyme Action Optimizer-Based FOPID Controller... [6]:** Se descarta porque PSO se utiliza exclusivamente como métrica de comparación (benchmark) para evaluar un nuevo optimizador enzimático, sin aportar desarrollos intrínsecos sobre PSO.
- **A Hybrid Feature Selection Method Using an Improved Binary Butterfly... [3]:** Su foco central es el Algoritmo de Optimización de Mariposa (BOA) para tareas de minería de datos; PSO solo se menciona marginalmente en el estado del arte.
- **A Multi-Strategy Seeker Optimization Algorithm... [5]:** Orientado a la validación del algoritmo MSSOA en problemas de diseño civil, donde PSO es delegado a ser únicamente un modelo base de control de desempeño.
- **A Nonlinear Adaptive Weight-Based Mutated Whale Optimization... [4]:** Presenta avances en el Whale Optimization Algorithm (WOA); la mención a PSO no profundiza en el entendimiento de su mecánica ni aplicaciones directas.
- **Design, Optimization, and Field... [10]:** Aunque es un artículo de control, aborda la sintonización general de PID evaluando múltiples metaheurísticas simultáneamente, aportando poco valor exclusivo a la comprensión profunda y singular de PSO.

Cuadro 1.3: Jerarquización y Categorización de la Literatura Seleccionada

Trabajo	Jerarquía Antecedentes		Estado del Arte	Trabajos Relacionados
[18]	Medio	Principios y fundamentos teóricos de PSO.	Avances y aplicaciones recientes del algoritmo.	Evaluación de desempeño en minería de datos y salud.
[15]	Alto	Modelos teóricos de análisis estructural.	Sistema PARS-Solution con algoritmos evolutivos.	Optimiza diseño de edificios de múltiples pisos.
[3]	Bajo	Mecanismos de búsqueda biológica en mariposas.	Integración de Adaptive Hill Climbing.	Reducción de espacio de búsqueda en datasets.

Trabajo	Jerarquía	Antecedentes	Estado del Arte	Trabajos Relacionados
[7]	Alto	Teoría de control en modo deslizante.	Optimización mediante búsqueda Bayesiana y PSO.	Ajusta controlador SMC en manipulador robótico.
[9]	Alto	Dinámica de actitud en cohetes de búsqueda.	Control NFTSMC mejorado con PSO global.	Estabiliza actitud de un cohete aeroespacial.
[8]	Alto	Fundamentos de acidificación de matrices.	Predicción mediante Extra-Trees y metaheurísticas.	Minimiza factor de daño en pozos petroleros.
[12]	Alto	Mecanismos de adaptación de referencia (MRAC).	Sinergia entre control adaptativo y optimización bioinspirada.	Sintoniza hiperparámetros de un controlador MRAC.
[6]	Bajo	Dinámica de reactores de tanque agitado.	Optimizador modificado basado en acción enzimática.	Regulación de temperatura en procesos químicos.
[11]	Alto	Optimización Human-in-the-loop (HIL).	Modelos sustitutos basados en EMG-RMS.	Simula y optimiza señales EMG biomecánicas.
[5]	Bajo	Limitaciones del Seeker Optimization Algorithm (SOA).	Estrategia de captura de sistema de triple agujero negro.	Resolución de 15 funciones Benchmark complejas.
[10]	Alto	Control de guiado en vehículos agrícolas.	Comparativa sistemática de 9 algoritmos metaheurísticos.	Optimiza controlador PI para pulverizador robótico.
[21]	Alto	Calidad de suelo en ingeniería civil.	Sintonización de CNN mediante algoritmos de enjambre.	Ajusta hiperparámetros CNN para clasificar suelos.
[2]	Medio	Funciones matemáticas con restricciones estrictas.	Hibridación TPOP-SOGWO basada en aprendizaje por oposición.	Diseño de recipientes a presión y vigas soldadas.

Trabajo	Jerarquía	Antecedentes	Estado del Arte	Trabajos Relacionados
[20]	Medio	Cinemática inversa en brazos robóticos.	Esquema RS-PSO usando teoría de conjuntos aproximados.	Planificación de trayectorias en cirugía robótica.
[1]	Medio	Estancamiento en modelos Crazy PSO".	Mejora convergencia mediante mutación adaptativa local.	Pruebas de precisión en funciones matemáticas.
[13]	Alto	Sistemas de péndulo invertido sobre carro.	Control adaptativo de referencia con gradiente fraccional.	Optimiza parámetros de control adaptativo fraccional.
[19]	Medio	Origen, conceptos matemáticos y ecuaciones base.	Topologías de vecindario y técnicas multi-enjambre.	Selección de características en señales digitales.
[14]	Medio	Control de sistemas dinámicos no lineales.	Algoritmo híbrido PSO-GWO para control no lineal.	Estabilización de osciladores tipo Duffing.
[4]	Bajo	Comportamiento de red de burbujas en ballenas.	Mutación basada en pesos adaptativos no lineales.	Optimización de diseño en ingeniería mecánica.
[17]	Alto	Configuración de cables dinámicos lazy-wave.	Optimización guiada por Machine Learning.	Diseña óptimamente cables dinámicos submarinos.

Artículo	Mecanismo / Estrategia	Operación Técnica	Reto de Ingeniería Solucionado
[22]	Integración de Mapas Caóticos (CAPSO)	Sustituye parámetros estocásticos tradicionales por secuencias deterministas caóticas en la fase de actualización, acelerando y diversificando la búsqueda.	Evasión de mínimos locales y convergencia prematura en espacios multimodales de ingeniería.

Artículo	Mecanismo / Estrategia	Operación Técnica	Reto de Ingeniería Solucionado
[23]	Hibridación BFOA-PSO	Acopla la quimiotaxis y reproducción de algoritmos de forrajeo bacteriano con la actualización de velocidad de PSO para balancear exploración/explotación.	Optimización en paisajes multimodales y diseño de códigos de radar de fase poli (alta dimensionalidad).
[24]	PSO Personalizado acoplado a modelos GIS	Ejecuta búsqueda continua para conectar curvas circulares y parabólicas simultáneamente, evaluando costos espaciales extraídos de mapas geográficos.	Diseño geométrico y alineamiento de carreteras con variables continuas infinitas y múltiples restricciones.
[25]	Optimización directa de parámetros NURBS	Modifica en paralelo iterativamente vectores de nodos, puntos de control y pesos mediante la actualización de enjambres para minimizar el error de ajuste.	Reconstrucción superficial a partir de nubes de puntos 3D ruidosas con topologías complejas.
[26]	MOPSO asistido por modelo sustituto (Kriging-HDMR)	Construye un metamodelo matemático adaptativo que PSO evalúa para deducir frentes de Pareto, evitando costosas simulaciones exhaustivas por CFD.	Costo computacional prohibitivo en dinámica termal y optimización multiobjetivo de baterías EV.
[27]	Estrategia de Pausa de Velocidad (VPPSO)	Introduce un grado de libertad adicional permitiendo a las partículas mantener su velocidad previa intacta, dividiendo el enjambre para mantener diversidad.	Estancamiento profundo en espacios hiperdimensionales y convergencia estancada.
[28]	Hibridación PSO-Harmony Search (PSO-HS y EPSO)	Aplica un término dinámico autoadaptativo durante la explotación local para guiar eficientemente la corrección del vector de sensibilidad del modelo.	Ineficiencia computacional en funciones de rendimiento discreto y confiabilidad estructural (FORM).
[29]	PSO Discreto-Mixto con Preservación Adaptativa	Mantiene la cinemática continua pero discretiza posiciones empleando el "vértice factible más cercano", repeliendo partículas del mejor global para variar.	Variables continuas-discretas acopladas y restricciones estrictas (ej. diseño de parques eólicos).

Artículo	Mecanismo / Estrategia	Operación Técnica	Reto de Ingeniería Solucionado
[30]	MOPSO con Búsqueda Dinámica de Frontera	Reasigna heurísticamente a las partículas que violan restricciones hacia los límites factibles del espacio, calibrando frentes no dominados.	Elevado número de variables de decisión y violaciones de restricciones en bioprocesos.
[31]	PSO Multiagente Dinámico	Los agentes (partículas) rastrean iterativamente las fronteras operativas simulando gradientes hacia los márgenes críticos de colapso del sistema.	Localización en tiempo real de límites de seguridad (vulnerabilidad) en redes eléctricas no lineales.
[32]	Selección Uniforme de Aptitud (FUSS) y Caminatas Aleatorias	Reduce la presión selectiva impuesta por líderes globales e inyecta "random Walks" que fuerzan saltos de exploración hacia zonas desconocidas.	Fuerte correlación de variables (linkage) y elusión de infinidad de óptimos locales (hasta 3000D).
[33]	Optimizador de Enjambre de Micro-partículas (μ PSO)	Opera con tamaños poblacionales minúsculos complementados por ciclos de reinicio o reposicionamiento constante para mantener diversidad sin alto costo.	Reconstrucción inversa electromagnética y de microondas (evaluaciones de diseño excesivamente caras).
[34]	GMPSO (Mutación de Ruido Blanco Gaussiano)	Combina métodos de superficie de respuesta con mutación probabilística mediante ruido blanco sobre el componente de posición para evitar convergencia nula.	Calibración/actualización de modelos de elementos finitos de alta dimensión usando excitación ambiental.
[35]	Coevolución Cooperativa vía Red Dinámica (FT-DNPSO)	Emplea clustering Fuzzy C-Means para subdividir la optimización masiva en subproblemas, acotando rangos con regiones de confianza variables.	Optimización a gran escala (Large-Scale Optimization) con variables que presentan fuerte dependencia.
[36]	MPSO con Distancia de Agrupamiento y Nichos	Archiva y selecciona el frente de Pareto midiendo distancias de agrupamiento; dirige la búsqueda hacia las zonas menos exploradas del archivo élite.	Obtención de frentes de Pareto discontinuos y cóncavos en optimización de diseño aerodinámico ferroviario.

Artículo	Mecanismo / Estrategia	Operación Técnica	Reto de Ingeniería Solucionado
[37]	Acoplamiento de Redes Neuronales Artificiales a PSO	Modela el comportamiento tenso-deformacional mediante una ANN que sirve como función de evaluación instantánea guiando las iteraciones del PSO.	Retro-estimación matemática (inversa y mal condicionada) de módulos elásticos en estructuras.
[38]	Micro MOPSO con aprendizaje por Kernel-PCA	Extrae componentes principales (PCA) de subespacios dimensionales, simplificando la evaluación masiva de restricciones probabilísticas del enjambre.	Optimización Many-Objective para la propagación de incertidumbre vibratoria (diseño por desempeño).
[39]	PSO Coevolutivo acoplado a Cuadratura Diferencial (DQ)	El PSO explora iterativamente parámetros dimensionales mientras la Cuadratura Diferencial resuelve de manera conjunta las ecuaciones de frontera asociadas.	Reducción de peso bajo perfiles termoelásticos severos en materiales funcionalmente graduados (FGM).
[40]	PSO Ortogonal (OPSO)	Divide el enjambre entre activos/pasivos, forzando la diagonalización ortogonal en la posición para que las trayectorias converjan sin redundancias bajo 1 guía.	Convergencia . ^{en} zigzag. ^{agravada} por limitaciones operacionales estrictas en micro-redes inteligentes.
[41]	Enjambre Social-Ingenieril (SEPSO)	Fusiona la jerarquía de atacante-defensor y memoria elitista para provocar grandes escapes algorítmicos durante estancamientos sin requerir sub-poblaciones.	Diagnóstico inverso de daño estructural tridimensional utilizando datos modales incompletos o ruidosos.

Referencias bibliográficas

- [1] S. Samal, S. K. Sarangi, and A. Sarangi, “Analysis of adaptive mutation in crazy particle swarm optimization,” in *2020 International Conference on Computational Intelligence for Smart Power System and Sustainable Energy (CISPSSE)*. IEEE, 7 2020, pp. 1–5. [Online]. Available: <https://ieeexplore.ieee.org/document/9212193/>
- [2] R. Katarya, U. Agrawal, and V. Rohatgi, “Optimizing constrained engineering problems using opposition based swarm algorithms,” in *Proceedings – 2021 3rd International Conference on Advances in Computing, Communication Control and Networking, ICAC3N 2021*. Institute of Electrical and Electronics Engineers Inc., 12 2021, pp. 861–867.
- [3] A. Tiwari, “A hybrid feature selection method using an improved binary butterfly optimization algorithm and adaptive β -hill climbing,” *IEEE Access*, vol. 11, pp. 93 511–93 537, 5 2023.
- [4] Z. Wang, Y. Li, L. Wu, and Q. Guo, “A nonlinear adaptive weight-based mutated whale optimization algorithm and its application for solving engineering problems,” *IEEE Access*, vol. 12, pp. 40 225–40 254, 1 2024.
- [5] S. Duan, H. Luo, and H. Liu, “A multi-strategy seeker optimization algorithm for optimization constrained engineering problems,” *IEEE Access*, vol. 10, pp. 7165–7195, 1 2022.
- [6] C. Turkeri, S. Ekinici, G. Yuksek, and D. Li, “A modified enzyme action optimizer-based FOPID controller for temperature regulation of a nonlinear continuous stirred tank reactor,” *Fractal and Fractional*, vol. 9, p. 811, 12 2025. [Online]. Available: <https://www.proquest.com/scholarly-journals/modified-enzyme-action-optimizer-based-fopid/docview/3286294597/se-2>
- [7] C. Castañeda, “AI-based optimization of a neural discrete-time sliding mode controller via bayesian, particle swarm, and genetic algorithms,” *Robotics*, vol. 14, p. 128, 9 2025.
- [8] S. M. Ebadi, E. Khamsehchi, and J. M. Kalatehno, “A comprehensive comparative analysis of particle swarm optimization and genetic algorithms in well acidizing optimization,” *Journal of Petroleum Exploration and Production Technology*, vol. 15, pp. 1–19, 3 2025.

- [9] Z. Cheng, C. Zhuo, and Q. Zhu, "Attitude control for hovering rocket decoy based on PSO-optimized sliding mode controller," *Journal of Physics: Conference Series*, vol. 3126, p. 012064, 10 2025.
- [10] A. Karamolachab, S. A. Mehdizadeh, and Y. Ampatzidis, "Design, optimization, and field evaluation of an automatic steering system for agricultural tractors using metaheuristic PID tuning," *Agriculture*, vol. 16, p. 1004, 5 2026. [Online]. Available: <https://www.mdpi.com/2077-0472/16/9/1004>
- [11] M. Gonabadi, N. H. Hunt, and F. Fallahtafti, "EMG-based simulation for optimization of human-in-the-loop control in simple robotic walking assistance," *Journal of Sensor and Actuator Networks*, vol. 14, p. 113, 12 2025.
- [12] M. A. Sadi, A. Jamali, M. A. Zulkifli, M. N. Leman, S. Mohamaddan, and H. Hazmi, "Enhanced control strategies for lower limb rehabilitation robots: A comparative study of MRAC, PID-ZN, and MRAC-PSO controllers," *Applied Bionics and Biomechanics*, vol. 2026, p. 8945626, 1 2026. [Online]. Available: <https://onlinelibrary.wiley.com/doi/10.1155/abb/8945626>
- [13] M. Sánchez, M. Duarte, L. Bárzaga, M. Orchard, and G. Ceballos, "Fractional gradient-based model reference adaptive control applied on an inverted pendulum-cart system," *Fractal and Fractional*, vol. 9, p. 485, 7 2025.
- [14] R. Vrabel, "Hybrid particle swarm and grey wolf optimization for robust feedback control of nonlinear systems," *Automation*, vol. 6, p. 89, 12 2025.
- [15] A. Baghdadi and H. Kloft, "Machine-learning-driven approaches for assessment, delegation, and optimization of multi-floor building structures," *Buildings*, vol. 15, p. 1565, 5 2025. [Online]. Available: <https://www.proquest.com/scholarly-journals/machine-learning-driven-approaches-assessment/docview/3203189815/se-2>
- [16] Y. Zhang, S. Wang, and G. Ji, "A comprehensive survey on particle swarm optimization algorithm and its applications," *Mathematical Problems in Engineering*, vol. 2015, p. 931256, 1 2015.
- [17] X. Zhao, Q. Ma, J. Li, Z. Wu, H. Lu, and Y. Xiong, "Optimization design of lazy-wave dynamic cable configuration based on machine learning," *Journal of Marine Science and Engineering*, vol. 13, p. 873, 4 2025. [Online]. Available: <https://www.mdpi.com/2077-1312/13/5/873>
- [18] L. Abualigah, "Particle swarm optimization: Advances, applications, and experimental insights," *Computers, Materials and Continua*, vol. 82, pp. 1539–1592, 2 2025.
- [19] T. M. Shami, A. A. El-Saleh, M. Alswaitti, Q. Al-Tashi, M. A. Summakieh, and S. Mirjalili, "Particle swarm optimization: A comprehensive survey," *IEEE Access*, vol. 10, pp. 10 031–10 061, 1 2022.

- [20] R. Nizar, “Rough sets meta-heuristic schema for inverse kinematics and path planning of surgical robotic arms,” *Robotics*, vol. 15, p. 52, 2 2026.
- [21] N. Yasir, F. Mahmood, M. Siddeeq, and M. Jaffer, “Enhanced CNN hyperparameter tuning via swarm intelligence for soil type classification,” 8 2025.
- [22] A. H. Gandomi, G. J. Yun, X.-S. Yang, and S. Talatahari, “Chaos-enhanced accelerated particle swarm optimization,” *Communications in Nonlinear Science and Numerical Simulation*, vol. 18, no. 2, pp. 327 – 340, 2013, cited by: 371. [Online]. Available: <https://www.scopus.com/pages/publications/84866000386?origin=resultslist>
- [23] A. Biswas, S. Dasgupta, S. Das, and A. Abraham, “Synergy of pso and bacterial foraging optimization - a comparative study on numerical benchmarks,” *Advances in Soft Computing*, vol. 44, pp. 255 – 263, 2007, cited by: 189. [Online]. Available: <https://www.scopus.com/pages/publications/61449110863?origin=resultslist>
- [24] Y. Shafahi and M. Bagherian, “A customized particle swarm method to solve highway alignment optimization problem,” *Computer-Aided Civil and Infrastructure Engineering*, vol. 28, no. 1, pp. 52 – 67, 2013, cited by: 165. [Online]. Available: <https://www.scopus.com/pages/publications/84871011304?origin=resultslist>
- [25] A. Gálvez and A. Iglesias, “Particle swarm optimization for non-uniform rational b-spline surface reconstruction from clouds of 3d data points,” *Information Sciences*, vol. 192, pp. 174 – 192, 2012, cited by: 159. [Online]. Available: <https://www.scopus.com/pages/publications/84857864608?origin=resultslist>
- [26] W. Zhang, Z. Liang, W. Wu, G. Ling, and R. Ma, “Design and optimization of a hybrid battery thermal management system for electric vehicle based on surrogate model,” *International Journal of Heat and Mass Transfer*, vol. 174, 2021, cited by: 158. [Online]. Available: <https://www.scopus.com/pages/publications/85104405939?origin=resultslist>
- [27] T. M. Shami, S. Mirjalili, Y. Al-Eryani, K. Daoudi, S. Izadi, and L. Abualigah, “Velocity pausing particle swarm optimization: a novel variant for global optimization,” *Neural Computing and Applications*, vol. 35, no. 12, pp. 9193 – 9223, 2023, cited by: 138; All Open Access; Green Open Access; Hybrid Gold Open Access. [Online]. Available: <https://www.scopus.com/pages/publications/85145706717?origin=resultslist>
- [28] S.-P. Zhu, B. Keshtegar, M. E. A. Ben Seghier, E. Zio, and O. Taylan, “Hybrid and enhanced pso: Novel first order reliability method-based hybrid intelligent approaches,” *Computer Methods in Applied Mechanics and Engineering*, vol. 393, 2022, cited by: 121. [Online]. Available: <https://www.scopus.com/pages/publications/85125233165?origin=resultslist>
- [29] S. Chowdhury, W. Tong, A. Messac, and J. Zhang, “A mixed-discrete particle swarm optimization algorithm with explicit diversity-preservation,” *Structural and*

- Multidisciplinary Optimization*, vol. 47, no. 3, pp. 367 – 388, 2013, cited by: 114. [Online]. Available: <https://www.scopus.com/pages/publications/84880569625?origin=resultslist>
- [30] M. Z. b. Mohd Zain, J. Kanesan, J. H. Chuah, S. Dhanapal, and G. Kendall, “A multi-objective particle swarm optimization algorithm based on dynamic boundary search for constrained optimization,” *Applied Soft Computing Journal*, vol. 70, pp. 680 – 700, 2018, cited by: 109; All Open Access; Green Open Access. [Online]. Available: <https://www.scopus.com/pages/publications/85048989639?origin=resultslist>
- [31] I. N. Kassabalidis, M. A. El-Sharkawi, R. J. Marks II, L. S. Moulin, and A. P. A. Da Silva, “Dynamic security border identification using enhanced particle swarm optimization,” *IEEE Transactions on Power Systems*, vol. 17, no. 3, pp. 723 – 729, 2002, cited by: 101. [Online]. Available: <https://www.scopus.com/pages/publications/0036699876?origin=resultslist>
- [32] Z. Cui, X. Cai, J. Zeng, and G. Sun, “Particle swarm optimization with fuss and rws for high dimensional functions,” *Applied Mathematics and Computation*, vol. 205, no. 1, pp. 98 – 108, 2008, cited by: 51. [Online]. Available: <https://www.scopus.com/pages/publications/54049084147?origin=resultslist>
- [33] T. Huang and A. Sanagavarapu Mohan, “A microparticle swarm optimizer for the reconstruction of microwave images,” *IEEE Transactions on Antennas and Propagation*, vol. 55, no. 3 I, pp. 568 – 576, 2007, cited by: 51. [Online]. Available: <https://www.scopus.com/pages/publications/34047204586?origin=resultslist>
- [34] Z. Xia, A. Li, J. Li, H. Shi, M. Duan, and G. Zhou, “Model updating of an existing bridge with high-dimensional variables using modified particle swarm optimization and ambient excitation data,” *Measurement: Journal of the International Measurement Confederation*, vol. 159, 2020, cited by: 49. [Online]. Available: <https://www.scopus.com/pages/publications/85082168705?origin=resultslist>
- [35] J. Fan, J. Wang, and M. Han, “Cooperative coevolution for large-scale optimization based on kernel fuzzy clustering and variable trust region methods,” *IEEE Transactions on Fuzzy Systems*, vol. 22, no. 4, pp. 829 – 839, 2014, cited by: 46. [Online]. Available: <https://www.scopus.com/pages/publications/84905572315?origin=resultslist>
- [36] S. Yao, D. Guo, Z. Sun, and G. Yang, “A modified multi-objective sorting particle swarm optimization and its application to the design of the nose shape of a high-speed train,” *Engineering Applications of Computational Fluid Mechanics*, vol. 9, no. 1, pp. 513 – 527, 2015, cited by: 43; All Open Access; Gold Open Access; Green Open Access. [Online]. Available: <https://www.scopus.com/pages/publications/84961328852?origin=resultslist>
- [37] K. Gopalakrishnan, “Neural network-swarm intelligence hybrid nonlinear optimization algorithm for pavement moduli back-calculation,” *Journal of Transportation Engineering*,

- vol. 136, no. 6, pp. 528 – 536, 2010, cited by: 42. [Online]. Available: <https://www.scopus.com/pages/publications/77955602655?origin=resultslist>
- [38] G. Li and H. Hu, “Risk design optimization using many-objective evolutionary algorithm with application to performance-based wind engineering of tall buildings,” *Structural Safety*, vol. 48, pp. 1 – 14, 2014, cited by: 42. [Online]. Available: <https://www.scopus.com/pages/publications/84894294846?origin=resultslist>
- [39] M. Khorsand and Y. Tang, “Design functionally graded rotating disks under thermoelastic loads: Weight optimization,” *International Journal of Pressure Vessels and Piping*, vol. 161, pp. 33 – 40, 2018, cited by: 40. [Online]. Available: <https://www.scopus.com/pages/publications/85042197178?origin=resultslist>
- [40] L. T. Al Bahrani and J. C. Patra, “Orthogonal pso algorithm for economic dispatch of thermal generating units under various power constraints in smart power grid,” *Applied Soft Computing Journal*, vol. 58, pp. 401 – 426, 2017, cited by: 40. [Online]. Available: <https://www.scopus.com/pages/publications/85019598848?origin=resultslist>
- [41] N. F. Alkayem, M. Cao, L. Shen, R. Fu, and D. Šumarac, “The combined social engineering particle swarm optimization for real-world engineering problems: A case study of model-based structural health monitoring,” *Applied Soft Computing*, vol. 123, 2022, cited by: 40. [Online]. Available: <https://www.scopus.com/pages/publications/85130378745?origin=resultslist>