


Matriz de Extracción de Artículos Científicos

Información general del estudiante

- **Nombre del estudiante:** Jaime Landázuri Román.
- **Técnica de IA:** Particle Swarm Optimization (PSO)
- **Pregunta de investigación:** ¿Cómo optimiza PSO problemas complejos en ingeniería?
- **Palabras clave:** Particle Swarm Optimization, PSO, engineering problems, complexity, constrained optimization, engineering design, computational efficiency.
- **Script:** ("Particle Swarm Optimization" OR "PSO") AND "engineering problems" AND "complexity"

Resultados de Búsqueda



Matriz de extracción

#	Referencia (IEEE)	Año	Base de datos	Técnica IA	Problema abordado	Objetivo del artículo	Metodología	Dataset / Contexto	Resultados principales	Limitaciones	Aporte para la PI
1	Z. Wang, Y. Li, L. Wu and Q. Guo, "A Nonlinear Adaptive Weight-Based Mutated Whale Optimization Algorithm and Its Application for Solving Engineering Problems," in IEEE Access, vol. 12, pp. 40225-40254,	2024	IEEE	PSO	La ineficiencia de los métodos tradicionales para resolver problemas de ingeniería	Proponer una variante mejorada del algoritmo de optimización de ballenas	Se integran tres estrategias: un factor de convergencia no lineal, pesos	Tres problemas clásicos de diseño en ingeniería: diseño de una armadura de tres	El algoritmo propuesto superó a variantes avanzadas de otros modelos, incluido el PSO, en	La introducción de nuevos mecanismos aumenta la complejidad	Muestra que técnicas como PSO optimizan problemas de ingeniería al ser

	2024, doi: 10.1109/ACCESS.2024.3350336.				de alta complejidad y la tendencia de los algoritmos metaheurísticos originales a estancarse en óptimos locales.	(WOA), denominada NAWM WOA, que equilibra y mejora la exploración y explotación para obtener soluciones más precisas y rápidas en ingeniería.	adaptativos y una estrategia de mutación híbrida.	barras (three-bar truss), diseño de un resorte de tensión-compresión y diseño de una viga soldada (welded beam).	términos de precisión y estabilidad.	computacional del modelo, lo que puede reducir la eficiencia de convergencia en términos de tiempo de ejecución comparado con versiones más simples.	utilizadas como base comparativa o híbrida para resolver problemas con restricciones (como estrés, frecuencia o deflexión en materiales). Específicamente, ofrece datos numéricos sobre cómo PSO maneja el diseño de estructuras frente a algoritmos más modernos, confirmando que estas técnicas son capaces de encontrar soluciones óptimas donde los métodos de cálculo tradicionales fallan por la complejidad de las variables.
2	A. Tiwari, "A Hybrid Feature Selection Method Using an Improved Binary Butterfly Optimization Algorithm and Adaptive β -Hill Climbing," in IEEE Access, vol. 11, pp. 93511-93537, 2023, doi: 10.1109/ACCESS.2023.3274469.	2023	IEEE	PSO	La ineficiencia de métodos tradicionales ante problemas de ingeniería con alta dimensionalidad y restricciones estrictas.	Mejorar el equilibrio entre la Exploración (expandir el espacio de búsqueda) y la Explotación	Integración de factores de convergencia no lineales y pesos adaptativos.	Uso del PSO como uno de los algoritmos de referencia estándar para comparar la eficiencia en la	En problemas como la viga soldada, se demuestra que las mejoras sobre los algoritmos base superan los resultados obtenidos	La introducción de nuevos mecanismos y la hibridación con otras técnicas aumentan la complejidad computacional	Indica que la optimización de problemas complejos no solo depende del algoritmo base (PSO por ejemplo), sino de su

						(determinar la mejor solución entre las producidos) para evitar caer en óptimos locales.		reducción del espacio de búsqueda.	por el PSO convencional (PSO: 1.820395 vs. Propuesto: 1.724852).	cional del algoritmo, lo que puede afectar la eficiencia en términos de tiempo total de procesamiento.	capacidad para ser modificada o mediante operadores estocásticos de vecindad y mutación. Esto demuestra que el PSO y sus derivados optimizan problemas complejos al permitir una transición fluida entre la búsqueda global (exploración) y la refinación local (explotación), adaptándose tanto a estructuras físicas como a la selección inteligente de datos.
3	R. Katarya, U. Agrawal and V. Rohatgi, "Optimizing Constrained Engineering Problems using Opposition based Swarm Algorithms," 2021 3rd International Conference on Advances in Computing, Communication Control and Networking (ICAC3N), Greater Noida, India, 2021, pp. 861-867, doi: 10.1109/ICAC3N5354.8.2021.9725575.	2021	IE EE	PSO	Los problemas de ingeniería del mundo real involucran funciones matemáticas complicadas con restricciones estrictas.	Combinar las capacidades de exploración y explotación de los algoritmos GWO y PSO para superar las limitaciones de los optimizadores tradicionales.	Hibridación en dos fases: Se aplican las técnicas de PSO y GWO a los mismos agentes de búsqueda en diferentes etapas, sin alterar las operaciones esenciales de los algoritmos clásicos.	Contexto de Aplicación: Diversos problemas de ingeniería industrial que presentan desafíos en áreas de búsqueda limitadas o inexploradas. Punto de Referencia: El	Superación de estándares : TPOPSO GWO sobrepasa a todos los optimizadores de enjambre tradicionales en múltiples problemas de ingeniería.	Aunque el abstract no las detalla explícitamente, se infiere que el éxito del algoritmo depende de la aplicación cuidadosa de ambas fases para no comprometer la esencia	El PSO aporta su capacidad de búsqueda mientras se apoya en otro algoritmo (GWO) para refinar los resultados. Manejo de la diversidad: La inclusión del "aprendizaje basado en

							algoritmo se mide contra optimizadores de enjambre tradicionales para demostrar su superioridad en entornos industriales reales.		de los algoritmos originales al combinarlos.	la oposición " es una técnica clave que permite al PSO explorar áreas del espacio de búsqueda que de otro modo quedarían ignoradas , evitando que el ingeniero obtenga soluciones mediocres (óptimos locales).
4	S. Samal, S. K. Sarangi and A. Sarangi, "Analysis of Adaptive Mutation in Crazy Particle Swarm Optimization," 2020 International Conference on Computational Intelligence for Smart Power System and Sustainable Energy (CISPSSE), Keonjhar, India, 2020, pp. 1-5, doi: 10.1109/CISPSSE49931.2020.9212193.	2020	IE EE	PSO	El PSO tradicional, aunque es una técnica popular y aceptada en problemas de ingeniería, presenta desventajas (cons) que limitan su desempeño.	Proponer una versión mejorada de la variante Crazy PSO denominada Adaptive mutated Crazy PSO.	Mecanismo de mejora: Se integra una mutación adaptativa dentro de la estructura del Crazy PSO. Simulación: Se realizaron experimentos de simulación para observar el comportamiento del algoritmo. Validación: El desempeño fue probado utilizando diversas funciones benchmark estándar.	El estudio se sitúa en el campo de la Inteligencia Colectiva (Swarm Intelligence), específicamente mejorando técnicas para problemas de ingeniería del mundo real. Punto de comparación: Los resultados del nuevo algoritmo se compararon directamente con el Crazy PSO básico para demostrar	Se observó que el Adaptive mutated Crazy PSO exhibió resultados significativamente mejores que el Crazy PSO original. La adición de la mutación adaptativa fue el factor clave que permitió alcanzar un mejor rendimiento global.	Se infiere que la modificación del algoritmo o busca equilibrar la convergencia, aunque el abstract no detalla si esto implica un costo computacional adicional en el tiempo de ejecución. Refinamiento de la búsqueda: Demuestra que el PSO no es una técnica estática, sino que su éxito en

								r la mejora.			ingeniería compleja depende de su capacidad de adaptación durante el proceso de búsqueda, ajustando su comportamiento según los resultados que va encontrando.
5	S. Duan, H. Luo and H. Liu, "A Multi-Strategy Seeker Optimization Algorithm for Constrained Engineering Problems," in IEEE Access, vol. 10, pp. 7165-7195, 2022, doi: 10.1109/ACCESS.2022.3141908.	2022	IE EE	PSO	El artículo aborda las deficiencias del Algoritmo de Optimización del Buscador (SOA) original. Específicamente, busca resolver problemas como la convergencia prematura, la baja precisión en la optimización, el estancamiento en óptimos locales y el desequilibrio entre los procesos de exploración y explotación en problemas de ingeniería con restricciones.	Propone y validar un Algoritmo de Optimización del Buscador Multi-estrategia (MSSOA). El objetivo es mejorar la capacidad de búsqueda global y la precisión del SOA mediante la integración de tres estrategias de interferencia para resolver problemas de optimización complejos.	Captura de sistema de triple agujero negro: Ayuda a los individuos a escapar de óptimos locales aumentando la diversidad de la población. Interferencia aleatoria multidimensional: Introduce pequeñas perturbaciones para corregir errores de desarrollo y mejorar la capacidad de búsqueda local.	15 funciones benchmark: Incluyen funciones unimodales (f1-f9) y multimodales (f10-f15) de alta dimensión. 5 ejemplos de problemas con restricciones: Problemas matemáticos estándar para probar la robustez. 6 problemas de diseño de ingeniería real: Incluyen el diseño de una viga soldada, recipientes a presión, viga en voladizo, columna tubular,	Superioridad en precisión: El MSSOA superó a PSO, SA, GA, GSA, SCA, MVO y SOA en la mayoría de las funciones benchmark y problemas de ingeniería. Robustez y Convergencia: Las pruebas de ANOVA y las curvas de convergencia demuestran que el MSSOA es altamente robusto y converge más rápido hacia el óptimo global. Equilibrio: El algoritmo mantuvo un excelente balance entre la	Complejidad computacional: El análisis de complejidad (Big-O) muestra que el MSSOA es más complejo que los algoritmos como PSO, MVO o el SOA básico. Tiempo de ejecución: El MSSOA tiene un tiempo de ejecución relativa mente largo, ocupando el sexto lugar de siete algoritmos comparados (siendo casi cuatro veces más	Aunque el enfoque principales MSSOA, el artículo describe cómo los algoritmos heurísticos (incluyendo el PSO) optimizan problemas complejos mediante la creación de métodos aleatorios y el uso de mecanismos de actualización de posición basados en la experiencia.

								palanca de pistón y viga de hormigón armado.	exploración del espacio de búsqueda y la explotación de las mejores soluciones encontradas.	lento que el SCA).	
--	--	--	--	--	--	--	--	--	---	--------------------	--

Síntesis del ejemplo

Al evaluar el rendimiento de diversos algoritmos de optimización (incluyendo el PSO y sus variantes), las fuentes coinciden en utilizar dos grandes categorías de ejemplos para someter a prueba a los modelos:

Funciones matemáticas de evaluación comparativa (Benchmark functions): Las investigaciones utilizan ampliamente funciones abstractas y complejas, tanto unimodales como multimodales (por ejemplo, funciones de De Jong, Powell, Levy, Rastrigin, Schwefel, entre otras), para probar rigurosamente la capacidad matemática, velocidad de convergencia y precisión de los algoritmos en diferentes dimensiones.

Problemas reales de diseño de ingeniería y minería de datos: Para demostrar la aplicabilidad práctica bajo restricciones estrictas (costos, peso, volumen, límites de tensión), las fuentes prueban los algoritmos en esquemas civiles y mecánicos clásicos. Los ejemplos más recurrentes incluyen el diseño de vigas en voladizo (cantilever), recipientes a presión, resortes de tensión/compresión, vigas soldadas, columnas tubulares, palancas de pistón y armaduras de tres barras. Adicionalmente, se aplican en la selección de características para la clasificación en la minería de datos, utilizando conjuntos de datos biológicos, financieros y físicos, así como en la optimización de parámetros para motores de combustión.

Respuesta a la pregunta de investigación

La Optimización por Enjambre de Partículas (PSO) es un algoritmo metaheurístico inspirado en el comportamiento de las bandadas de aves migratorias, diseñado para localizar soluciones casi óptimas en espacios de alta dimensión. Su forma de optimizar problemas complejos se basa en los siguientes mecanismos y evoluciones:

Mecanismo base del algoritmo PSO: El PSO utiliza una "población" de partículas donde cada una representa una solución potencial. Cada partícula posee dos parámetros fundamentales: posición y velocidad. En cada iteración, las partículas actualizan su trayectoria guiándose por dos valores memorizados:

- **Personal_best:** La mejor posición que ha encontrado la partícula individualmente.
- **Global_best:** La mejor posición encontrada por todo el enjambre en conjunto. Al combinar estos valores, las partículas ajustan su velocidad y dirección, "conduciendo" al enjambre gradualmente hacia la solución óptima del problema matemático.

Fortalezas en la Explotación: En problemas de ingeniería, el PSO destaca por su notable capacidad de "explotación", es decir, es excelente para refinar y encontrar la solución óptima en una región de búsqueda cercana o localizada. De hecho, ante ciertos problemas restringidos (como

el diseño de vigas de hormigón armado), el PSO clásico logra igualar o incluso superar los resultados de otros algoritmos más recientes al encontrar el costo o peso mínimo de los materiales.

Superación de sus deficiencias en problemas complejos: Dado que los problemas reales de ingeniería tienen múltiples restricciones y mínimos locales, el PSO básico tiende a sufrir de convergencia prematura (quedar atrapado en un subóptimo local) debido a su débil capacidad de "exploración" general del espacio de búsqueda. Para optimizar con éxito problemas de altísima complejidad, el modelo PSO se modifica y fortalece de las siguientes maneras:

- **Hibridación compensatoria:** Se integra el PSO con otros algoritmos para equilibrar la búsqueda. Por ejemplo, el modelo TPOPSOGWO combina la fuerte explotación del PSO con la poderosa capacidad de exploración del Optimizador de Lobo Gris (GWO), logrando navegar espacios desconocidos de ingeniería y evitando los mínimos locales.
- **Probabilidad de "Locura" (Crazy PSO):** Para evitar que el *global_best* arrastre prematuramente al enjambre a un error local, se introduce una "probabilidad de locura". Esta función altera aleatoriamente la velocidad de las partículas, forzándolas a salir de la región actual y explorar nuevas áreas del dominio.
- **Mutación Adaptativa:** Al *Crazy PSO* se le puede integrar una fase de mutación adaptativa (ACPSO). Esto incrementa dramáticamente la precisión de los resultados en funciones complejas, logrando reducir los costos de diseño con un menor número de iteraciones computacionales.
- **Aprendizaje basado en la oposición (OBL):** En lugar de inicializar las partículas del PSO de forma puramente aleatoria, se generan posiciones aleatorias y también sus posiciones matemáticamente "opuestas". Esto garantiza una mejor diversidad en la población desde el inicio, incrementando las probabilidades de que el PSO aterrice en la solución óptima más rápido.