

Fundamentos de Inteligencia Artificial Clásica: Técnicas, Métodos y Aplicaciones Antes de la IA Generativa

Luis Chamba-Eras

Editor

2026

Índice general

I	Introducción y Fundamentos	1
II	Aprendizaje Estadístico y Modelos de Clasificación	2
1.	Optimización mediante PSO en Ingeniería	3
1.1.	Introducción	3
1.2.	Fundamentos Teóricos de PSO	4
1.3.	Evolución y Variantes del Algoritmo	6
1.3.1.	Topologías de Enjambre	6
1.3.2.	PSO Multiobjetivo (MOPSO)	7
1.3.3.	Hibridaciones y Sinergias Algorítmicas	7
1.4.	Aplicaciones en la Ingeniería	8
1.4.1.	Ingeniería de Computación y Software	8
1.4.2.	Diseño Electrónico y Sistemas Digitales	8
1.4.3.	Sistemas de Energía y Potencia	9
1.4.4.	Procesamiento de Señales y Sistemas Embebidos	9
1.4.5.	Logística, Enrutamiento y Sistemas de Información	10
1.5.	Análisis de Complejidad Computacional	13
1.6.	Conclusiones	14

Parte I

Introducción y Fundamentos

Parte II

Aprendizaje Estadístico y Modelos de Clasificación

Capítulo 1

Optimización de Sistemas de Ingeniería mediante el Algoritmo de Optimización por Enjambre de Partículas (PSO)

Autor: Jaime Alejandro Landázuri Román (jaime.landazuri@unl.edu.ec)

Técnica asignada: Optimización por Enjambre de Partículas (PSO)

1.1. Introducción

La optimización de sistemas de ingeniería constituye el núcleo fundamental para la toma de decisiones críticas en el diseño, control, operación y manufactura en la industria moderna [1–3]. En la práctica, el objetivo principal radica en seleccionar la "mejor" alternativa dentro de un hiperespacio predefinido para minimizar costos, maximizar la eficiencia o lograr un equilibrio óptimo entre objetivos diametralmente en conflicto [1, 4]. Tradicionalmente, la resolución de estas formulaciones se cimentaba en métodos analíticos, técnicas deterministas y algoritmos de optimización basados en el descenso del gradiente [5, 6]. Sin embargo, el avance y la creciente sofisticación de las aplicaciones en el mundo real han evidenciado de manera innegable las graves limitaciones intrínsecas de estos enfoques clásicos, los cuales fracasan estrepitosamente al intentar converger ante la naturaleza inherentemente intrincada de los problemas de ingeniería contemporáneos [1, 5, 7]. La raíz de este fracaso analítico se explica a través de tres características matemáticas y fenomenológicas formidables presentes en el modelado de estos sistemas: su alta y compleja no linealidad, la topografía fuertemente multimodal de su función objetivo y la rigurosa sujeción a restricciones limitantes [2, 8, 9]. En primer lugar, los problemas complejos en ingeniería están dominados por una profunda **no linealidad** y, en una multitud de escenarios, por la falta de diferenciabilidad matemática [1, 10]. Técnicamente, esto obedece a que las interacciones acopladas entre múltiples variables de diseño (que pueden ser continuas, discretas o mixtas) configuran hiper-superficies irregulares que no pueden simplificarse mediante relaciones algebraicas proporcionales [8, 11, 12]. Particularmente en sistemas modernos, las evaluaciones de desempeño dependen a menudo de simulaciones de caja negra (como el análisis avanzado de elementos finitos), donde los gradientes de la función objetivo son inexistentes, numéricamente inestables o su cálculo exige un coste computacional inasequible [3, 13]. Sumado a esto, el aumento drástico en la dimensión de los parámetros a optimizar desencadena el devastador fenómeno de la "maldición de la dimensionalidad", generando fuertes correlaciones no lineales que las rutinas deterministas son incapaces de descifrar de manera efectiva [6, 13–15]. En segundo lugar, la extrema **multimodalidad** del espacio de soluciones erige una barrera formidable que condena al fracaso a los esquemas de optimización convencionales [9, 11, 16, 17]. Matemáticamente, una función multimodal-

dal es aquella que alberga una gran cantidad de óptimos locales o "valles de engaño" distribuidos por todo el espacio de búsqueda, enmascarando la verdadera ubicación del óptimo global [5, 10]. Los métodos numéricos basados en derivadas sufren de una vulnerabilidad letal respecto a sus condiciones iniciales: una vez que la trayectoria de búsqueda ingresa en la cuenca de atracción de un óptimo local, el algoritmo carece de mecanismos matemáticos para escapar y la convergencia se detiene de forma prematura y deficiente [2, 5, 14, 15, 18, 19]. Para abordar con éxito topologías de este calibre (como en sintonizaciones de controladores no lineales, modelado de sistemas de energía o perfiles aerodinámicos), resulta mandatorio desplegar arquitecturas de búsqueda que logren un equilibrio estocástico perfecto entre la exploración divergente del espacio completo y la explotación intensiva de las vecindades prometedoras [9, 20, 21]. En tercer lugar, todo diseño ingenieril de vanguardia está indisolublemente **sujeto a restricciones estrictas**, delimitando agresivamente la factibilidad operativa del dominio de búsqueda [4, 22, 23]. Estas restricciones se modelan como elaborados sistemas de ecuaciones e inecuaciones no lineales que proyectan los límites insuperables de la física, la mecánica de materiales, los confines geométricos o las fronteras de rentabilidad financiera del diseño, tales como tolerancias máximas de esfuerzo, límites en la frecuencia de resonancia o deflexiones volumétricas permitidas [2, 6, 20–22]. La inyección de estas severas penalizaciones topológicas suele seccionar y distorsionar fuertemente el espacio factible, provocando que soluciones teóricamente óptimas sean pragmáticamente inviables [21, 24]. Para resolver esta fragmentación matemática, el motor de optimización debe soportar estrategias avanzadas de manejo de restricciones o funciones de penalización, capaces de discernir y descartar dinámicamente las configuraciones que amenazan los estrictos estándares de integridad y seguridad del modelo [4, 18, 22, 23]. Como respuesta contundente a la profunda incapacidad técnica de los métodos analíticos ortogonales para converger en entornos simultáneamente no lineales, caóticamente multimodales y sumamente restringidos, la academia y la industria han adoptado sin reservas los algoritmos de optimización metaheurística basados en inteligencia de enjambre [2, 5, 11, 25]. Estos enfoques poblacionales se independizan completamente de la información del gradiente y emplean lógicas estocásticas de auto-organización, lo que les confiere una adaptabilidad y una evasión de óptimos locales sin precedentes [3, 8, 26]. En el ápice de estas tecnologías subyace el Algoritmo de Optimización por Enjambre de Partículas (PSO), introducido originalmente por Kennedy y Eberhart; un esquema heurístico que se ha posicionado de manera universal y categórica como la herramienta definitiva debido a su eficiente paralelización computacional, su simplicidad algorítmica y su resiliente capacidad matemática para amalgamar la inteligencia cognitiva individual con la inteligencia social del ecosistema a fin de alcanzar soluciones de calidad global de forma iterativa [1, 3, 16, 21, 25, 27]. Dado que la dependencia de los métodos matemáticos y analíticos convencionales está inherentemente condenada al estancamiento en la nueva era del diseño algorítmico, el presente trabajo procederá a diseccionar con rigor técnico y matemático la mecánica interna de esta poderosa metaheurística estocástica que ha transformado la ingeniería contemporánea. Se detallarán los vectores de velocidad iterativa, la arquitectura de su red social y las estrategias adaptativas de hiperparámetros de esta técnica, lo que servirá como sustrato analítico para dar respuesta a la inminente interrogante central de esta investigación: ¿Cómo optimiza PSO problemas complejos en ingeniería?

1.2. Fundamentos Teóricos de PSO

El Algoritmo de Optimización por Enjambre de Partículas (PSO), en su formulación clásica, opera mediante la simulación de la dinámica social de un enjambre en el que cada individuo (partícula) representa una solución candidata dentro de un hiperespacio de búsqueda de D dimensiones [1, 3, 21]. La transición de las partículas hacia regiones óptimas se gobierna a través de un proceso iterativo continuo fundamentado en dos ecuaciones matemáticas elementales que actualizan, respectivamente, el vector de velocidad $v_i(t)$ y el vector de posición $x_i(t)$ de la i -ésima partícula [13, 26, 28]. Dichas ecuaciones se expresan rigurosamente como:

$$v_i(t+1) = \omega v_i(t) + c_1 r_1 (pbest_i - x_i(t)) + c_2 r_2 (gbest - x_i(t)) \quad (1.1)$$

$$x_i(t+1) = x_i(t) + v_i(t+1) \quad (1.2)$$

En esta formulación, la convergencia y la trayectoria estocástica del enjambre dependen de un delicado equilibrio cinemático dictado por los hiperparámetros del sistema [2, 5]. Los coeficientes de aceleración, c_1 (coeficiente cognitivo) y c_2 (coeficiente social), cuantifican la confianza estocástica que la partícula deposita en su propia memoria heurística frente a la inteligencia colectiva del enjambre [1, 21, 29]. Desde una perspectiva analítica, un valor desproporcionadamente alto de c_1 empuja a las partículas a vagar de forma aislada alrededor de sus óptimos históricos locales, maximizando la diversidad pero ralentizando severamente la convergencia global [21, 29]. Por el contrario, un c_2 predominante genera una atracción gravitacional masiva hacia el óptimo global actual ($gbest$), lo que acelera dramáticamente la velocidad de convergencia, pero introduce una vulnerabilidad crítica: la propensión a la convergencia prematura en valles subóptimos [13, 29]. Para inyectar la necesaria aleatoriedad ergódica, las variables r_1 y r_2 actúan como vectores aleatorios extraídos de una distribución uniforme en el intervalo [1, 3].

El parámetro más trascendental introducido para estabilizar el sistema dinámico es el peso de inercia (ω). Físicamente, ω determina el grado en que la velocidad previa se conserva, operando como un amortiguador matemático que regula la tensión algorítmica entre la exploración (búsqueda divergente global) y la explotación (refinamiento convergente local) [1, 13, 30]. Un valor de ω elevado en las fases iniciales proporciona el momento cinético requerido para que el enjambre trascienda los límites locales y explore ampliamente el panorama de la función objetivo. A medida que el algoritmo avanza, se requiere que la energía cinética se disipe para facilitar un micro-refinamiento exhaustivo en la vecindad de la solución óptima descubierta [7, 8, 15]. Para modelar esta transición fenomenológica, se implementa comúnmente una estrategia de variación temporal con decaimiento lineal, formalizada mediante la siguiente ecuación:

$$\omega(t) = \omega_{max} - \frac{\omega_{max} - \omega_{min}}{t_{max}} \times t \quad (1.3)$$




Figura 1.1: Estrategias de variación temporal para el decaimiento del peso de inercia (ω) en PSO a lo largo de 100 iteraciones. Se ilustra la transición desde una fase de exploración agresiva ($\omega = 0,9$) hacia una de explotación microscópica ($\omega = 0,4$). Además del decaimiento lineal clásico formulado en la Ecuación 1.3, se contrastan enfoques avanzados como el decaimiento exponencial (que acelera la transición hacia la explotación) y el mapeo caótico (que inyecta estocasticidad para evitar óptimos locales).

Donde ω_{max} (típicamente 0,9) y ω_{min} (típicamente 0,4) representan los límites superior e inferior del momento de inercia, t es la iteración actual y t_{max} es el límite máximo de iteraciones [7, 21, 30]. Este decaimiento asegura una metamorfosis fluida y matemáticamente estable desde un régimen de exploración agresiva hacia uno de explotación microscópica, mitigando sustancialmente las inestabilidades oscilatorias [15, 30].




Figura 1.2: Representación vectorial de la actualización cinemática de las partículas en un espacio bidimensional (d_1, d_2). Nótese la equivalencia de notación con las Ecuaciones 1.1 y 1.2: el instante actual se denota como k (equivalente a t), el óptimo personal o vector de memoria es $b^i[k]$ (equivalente a $pbest_i$), y el óptimo global o vector de cooperación es $b_G[k]$ (equivalente a $gbest$) [31].

1.3. Evolución y Variantes del Algoritmo

A pesar de su robustez teórica, el algoritmo PSO clásico sufre de deficiencias estructurales intrínsecas, primariamente manifestadas en su convergencia prematura o estancamiento.^{a)} Al enfrentar paisajes de optimización multimodales fuertemente no lineales [1, 5, 14]. Al escalar la dimensionalidad del problema, el enjambre experimenta la denominada "maldición de la dimensionalidad", donde la rápida propagación de la información de un óptimo local subyuga la diversidad del sistema y colapsa la búsqueda de manera deficiente [13, 15, 21]. Para contrarrestar esta limitación, la ingeniería computacional ha derivado modificaciones arquitectónicas de vanguardia.

1.3.1. Topologías de Enjambre

La dinámica del flujo de información está intrínsecamente ligada a la estructura de la red social o "topología de vecindario" del enjambre [21, 25]. En la topología original de *estrella* (o modelo *gbest*), todas las partículas están interconectadas, permitiendo que la información del mejor individuo se disemine instantáneamente, lo cual maximiza la velocidad de convergencia pero cristaliza el riesgo de atrapamiento local [15, 21, 25]. Para descentralizar el aprendizaje,

variantes de topología en *anillo* (modelo *lbest*) restringen la comunicación únicamente a partículas adyacentes; esto retrasa deliberadamente la transmisión de información, garantizando una exploración más heterogénea y conservando la diversidad poblacional [13, 21]. Estructuras más sofisticadas, como la topología de *von Neumann* (un retículo bidimensional), han demostrado ofrecer un equilibrio empírico superior, conectando a cada partícula con cuatro vecinos (arriba, abajo, izquierda y derecha), lo que amortigua la convergencia sin sacrificar dramáticamente la velocidad computacional [13, 21, 25].




Figura 1.3: Representación visual de las topologías de vecindario fundamentales que estructuran la red social en PSO: a) Topología en anillo o local (*lbest*), que restringe la comunicación para promover una exploración exhaustiva y conservar la diversidad; b) Topología global o de estrella (*gbest*), donde la interconexión total maximiza la velocidad de convergencia; y c) Topología de von Neumann en cuadrícula, que proporciona un equilibrio empírico superior entre exploración y explotación [32].

1.3.2. PSO Multiobjetivo (MOPSO)

En la ingeniería moderna, los problemas rara vez se reducen a la minimización de un escalar solitario; por el contrario, exigen la optimización simultánea de múltiples metas en competencia [1, 27]. Por ejemplo, en el diseño de un componente aeronáutico, existe una necesidad ineludible de maximizar la resistencia estructural y la rigidez mecánica, al mismo tiempo que se minimiza drásticamente el peso de los materiales y los costos de manufactura. Para resolver este conflicto matemático sin colapsar las funciones, surge el PSO Multiobjetivo (MOPSO), una adaptación que abandona la noción de un único óptimo global para adoptar el principio de la dominancia de Pareto [3, 27]. En MOPSO, el enjambre almacena un repositorio externo de soluciones no dominadas (el Frente de Pareto), desde el cual se seleccionan probabilísticamente los guías globales, permitiendo a los ingenieros evaluar el espectro de compromisos ("trade-offs") de manera simultánea e integral [3, 33].

1.3.3. Hibridaciones y Sinergias Algorítmicas

La deficiencia del PSO en su fase tardía de búsqueda radica en su falta de operadores de salto probabilístico o de mutación evolutiva; por ello, la vanguardia algorítmica propone arquitecturas híbridas [1, 3, 21]. Una integración destacada en sistemas dinámicos no lineales es la hibridación con el Optimizador de Lobo Gris (PSO-GWO). El GWO aporta su superior jerarquía de exploración divergente basada en las presas (lobos α, β, δ) para dominar las fases tempranas e intermedias, evadiendo óptimos locales, mientras que PSO asume el rol de explotación acelerada

en las regiones prometedoras descubiertas, resultando en una reducción drástica en la evaluación de la función de costo [9].

De igual forma, la amalgama teórica con Algoritmos Genéticos (GA) introduce operadores estocásticos de *crossover* y *mutación* dentro del ciclo de actualización del PSO, garantizando una inyección continua de diversidad genética en el enjambre que perturba las posiciones estancadas [1, 3, 19]. Adicionalmente, hibridaciones con metodologías de Recocido Simulado (SA) equipan a la partícula con una probabilidad termodinámica de aceptar soluciones degradadas temporalmente, un mecanismo crítico que faculta al enjambre para escapar de mínimos locales profundos simulando el temple metalúrgico, probando ser vital para la resolución de funciones de hiper-superficies fuertemente caóticas [1, 3].

1.4. Aplicaciones en la Ingeniería

La extraordinaria versatilidad matemática y la resiliencia algorítmica del Algoritmo de Optimización por Enjambre de Partículas (PSO) le han permitido trascender la teoría computacional para consolidarse como un motor de resolución estándar en diversas ramas de la ingeniería aplicada. Al operar eficientemente en espacios de búsqueda continuos y discretos de alta dimensionalidad, y al independizarse de la necesidad de gradientes derivables, PSO ha demostrado una capacidad superior para converger hacia óptimos globales en entornos pragmáticos caracterizados por ruido, multimodalidad y restricciones severas, superando sistemáticamente a los enfoques deterministas clásicos [1, 3, 21]. A continuación, se detalla la evidencia contemporánea sobre el impacto de esta metaheurística estocástica en disciplinas ingenieriles críticas.

1.4.1. Ingeniería de Computación y Software

En el ámbito de la ingeniería de computación y el desarrollo de arquitecturas de software, PSO se ha convertido en un pilar para la optimización de infraestructuras tecnológicas complejas y el procesamiento masivo de datos. Una de sus implementaciones más críticas radica en el ajuste riguroso de hiperparámetros para modelos avanzados de *Machine Learning* y arquitecturas de redes neuronales profundas (DNNs y CNNs). Mediante la exploración multidimensional, PSO sintoniza dinámicamente tasas de aprendizaje, coeficientes de regularización, factores de penalización en Máquinas de Vectores de Soporte (SVM) y la densidad de unidades en capas ocultas, maximizando la precisión de clasificación y reduciendo drásticamente tanto el sobreajuste como los tiempos de entrenamiento computacional en comparación con las metodologías tradicionales de búsqueda en cuadrícula (*Grid Search*) o aleatoria [1, 34, 35]. Simultáneamente, la metaheurística aborda con éxito desafíos de asignación de recursos en entornos de infraestructura como código. En clústeres de servidores y entornos distribuidos de contenedores (*Cloud Computing* y *Edge Computing*), algoritmos como el PSO Modificado (MALPSO) y otras variantes híbridas ejecutan un balanceo de carga algorítmico altamente eficiente. Esto minimiza el tiempo de finalización (*makespan*), asegura la estabilidad del sistema y maximiza la eficiencia en el uso de los recursos computacionales virtuales [1, 21]. Asimismo, en ecosistemas de *Big Data* y bases de datos distribuidas o no relacionales, PSO se emplea en la optimización de consultas complejas y la selección de características (*Feature Selection*) en espacios de alta dimensionalidad. Al descartar heurísticamente variables redundantes y optimizar las rutas de acceso a los datos, PSO logra reducir significativamente la latencia de las transacciones y los márgenes de error, garantizando una topología de red de datos depurada y de alta velocidad [1, 21, 36].

1.4.2. Diseño Electrónico y Sistemas Digitales

El diseño electrónico y la automatización de sistemas digitales requieren tolerancias milimétricas y respuestas transitorias de alta precisión, escenarios donde el PSO ha demostrado una

eficacia sin precedentes. A nivel de control de hardware industrial y robótico, el algoritmo se utiliza extensivamente para la sintonización rigurosa de parámetros en controladores Proporcional-Integral-Derivativo (PID) clásicos y de orden fraccionario (FOPID). A través de la minimización iterativa de índices de desempeño integral (como el ITAE o el error cuadrático medio), PSO, especialmente hibridado con algoritmos como el Optimizador de Lobo Gris (PSO-GWO), logra estabilizar sistemas de control robusto altamente no lineales —como osciladores caóticos, reactores químicos continuos (CSTR), sistemas de suspensión activa y péndulos invertidos— amortiguando el sobreimpulso, eliminando el error en estado estacionario y reduciendo radicalmente los tiempos de estabilización frente a las clásicas metodologías de Ziegler-Nichols [9, 20, 30, 33, 37, 38]. Adicionalmente, en la arquitectura de hardware, PSO interviene en la síntesis y el diseño de componentes físicos, facilitando la optimización geométrica y el enrutamiento de alta densidad en placas de circuito impreso (PCB) para minimizar las interferencias electromagnéticas cruzadas. En el procesamiento digital de señales y diseño de transceptores, la variante de PSO de comportamiento cuántico y las hibridaciones mutacionales se emplean para la calibración precisa de filtros digitales de respuesta al impulso finita e infinita (FIR/IIR), ecualización de canales adaptativos y el diseño de perfiles de códigos polifásicos para radares, asegurando un margen de error menor y una mayor fidelidad de la señal en redes de comunicación MIMO-OFDM [16, 21].

1.4.3. Sistemas de Energía y Potencia

La gestión eficiente de los recursos energéticos a gran escala representa uno de los mayores desafíos logísticos del siglo XXI, para el cual PSO ha ofrecido soluciones algorítmicas transformadoras. El sector eléctrico emplea formulaciones avanzadas de PSO (como el PSO Ortogonal y adaptativo) para resolver el complejo problema del Despacho Económico de Energía (ED). Esta tarea exige la asignación óptima de las cargas de demanda entre múltiples unidades de generación térmica para minimizar estrictamente los costos operativos del combustible. PSO navega este panorama altamente no convexo resolviendo simultáneamente inecuaciones severas de la red, tales como los límites de tasa de rampa (RRLs), las zonas de operación prohibida (POZs) de los generadores y las pérdidas de transmisión, convergiendo con un coste computacional ínfimo frente a esquemas de programación lineal [1, 14, 21]. En la transición contemporánea hacia las redes eléctricas inteligentes (*Smart Grids*), la penetración de generación distribuida introduce estocasticidad en la matriz energética. En este contexto, PSO se aplica para determinar estratégicamente la ubicación topológica y el dimensionamiento óptimo de generadores basados en energías renovables (como arreglos fotovoltaicos y turbinas eólicas) junto con sistemas de almacenamiento en baterías. Al optimizar los parámetros de la red distribuida, el algoritmo no solo maximiza la inyección de energía verde y reduce las emisiones de carbono, sino que minimiza la dependencia de la red principal, mejora sustancialmente el perfil de tensión en los nodos y minimiza las pérdidas activas del sistema, garantizando una operación unificada, resiliente y económicamente viable [1, 21].

1.4.4. Procesamiento de Señales y Sistemas Embebidos

En la vanguardia de la electrónica moderna y el diseño de hardware, el Algoritmo de Optimización por Enjambre de Partículas (PSO) y sus arquitecturas de variables mixtas (MVOPs) o discretas (MDPSO) han demostrado una eficacia formidable para la sintonización paramétrica de sistemas físicos continuos y redes lógicas [1, 8]. En el dominio de la instrumentación y el diseño de hardware analógico, la formulación matemática de un circuito exige seleccionar configuraciones exactas a partir de catálogos comerciales limitados, transformando la tarea en un complejo problema de búsqueda no convexa y multidimensional [8]. PSO resuelve este desafío mapeando los valores de los componentes físicos directamente en el vector de posición x_i de cada partícula, permitiendo al algoritmo navegar a través de un espacio de búsqueda continuo o discreto para hallar combinaciones óptimas que los métodos analíticos convencionales no pueden

deducir [1, 12]. Un caso de estudio paradigmático se observa en las aplicaciones de audio de alta fidelidad, tales como el diseño riguroso de pedales de efectos analógicos. En este escenario, la metaheurística realiza la selección óptima y precisa de componentes pasivos y activos, obligando al vector de posición a converger hacia especificaciones comerciales de tolerancia estricta, especificando valores exactos como capacitores electrolíticos, amplificadores operacionales tipo TL072CP o potenciómetros lineales de 10K [3, 21]. La validación del circuito se fundamenta en una función de evaluación (fitness) que cuantifica el rendimiento dinámico del sistema; el algoritmo evalúa iterativamente el hiperespacio de diseño para minimizar la función de error cuadrático o absoluto entre la curva de filtrado real del hardware propuesto y una respuesta de frecuencia ideal predefinida, ajustando rigurosamente parámetros críticos como la atenuación, la ganancia de banda y el desfase de la señal [16, 21]. Paralelamente, en el ámbito de la Síntesis Lógica y los Sistemas Embebidos Digitales, las variantes binarias (BPSO) y discretas (DPSO) de la metaheurística han emergido como motores de resolución indispensables para los problemas de optimización combinatoria inherentes a la automatización del diseño electrónico (EDA) [3, 21]. A diferencia del hardware analógico, en la descripción de hardware estructurado mediante lenguajes como VHDL, el vector de posición de la partícula codifica transiciones binarias o topologías de red que representan los estados de asignación de puertas lógicas. De esta manera, PSO ejecuta una asignación eficiente de recursos, optimizando el enrutamiento de pistas conductoras y la síntesis de compuertas lógicas complejas para circuitos secuenciales de alta densidad [3]. La aplicación de esta inteligencia de enjambre resulta vital durante la optimización de módulos digitales simulados e implementados en plataformas avanzadas de arreglos de compuertas programables (FPGAs) como Xilinx Vivado. A medida que las partículas iteran y actualizan su velocidad estocástica impulsadas por sus memorias cognitivas y sociales, el algoritmo descarta heurísticamente arquitecturas redundantes para minimizar métricas críticas impuestas por las restricciones físicas del silicio. Consecuentemente, el enjambre minimiza el área de silicio total consumida por el circuito, mitiga drásticamente el consumo de potencia de conmutación dinámica en los transistores y reduce el retardo de propagación crítico de las señales a lo largo de las rutas combinacionales más largas del sistema [3, 21]. En su conjunto, la convergencia de PSO en estos entornos discretos certifica el desarrollo de plataformas de procesamiento de señales y arquitecturas digitales que no solo cumplen con los requerimientos teóricos, sino que maximizan la eficiencia energética y espacial en la ingeniería de sistemas embebidos.

1.4.5. Logística, Enrutamiento y Sistemas de Información

La gestión logística y la telemetría en tiempo real imponen desafíos computacionales críticos donde el Algoritmo de Optimización por Enjambre de Partículas (PSO) ha demostrado una capacidad de convergencia superior. En el contexto de redes de recolección de datos logísticos y sistemas del Internet de las Cosas (IoT), PSO gestiona y optimiza de manera estocástica las rutas de transmisión de información para minimizar la latencia de la red [1, 21]. Un caso de estudio paradigmático es la configuración y sincronización de sistemas de rastreo GPS para la recepción de tramas provenientes de dispositivos de telemetría de alta frecuencia (como los equipos de la arquitectura Teltonika). Al modelar la topología de la red de transmisión, las partículas del enjambre evalúan iterativamente el hiperespacio de soluciones para identificar rutas de acceso óptimas, reduciendo drásticamente la latencia en la entrega de *payloads* telemétricos [3, 21]. Simultáneamente, el motor algorítmico del PSO se implementa para resolver las variaciones dinámicas del Problema de Enrutamiento de Vehículos (VRP, por sus siglas en inglés). Mediante la actualización continua de sus vectores de velocidad y posición, la metaheurística evade colapsos locales y optimiza de manera global el flujo ininterrumpido de datos telemétricos hacia los servidores centrales, mitigando eficazmente la formación de cuellos de botella en la red de comunicaciones [1, 3]. A nivel de infraestructura de software, la integración de PSO en arquitecturas *backend* modernas constituye un avance trascendental para la orquestación y optimización de recursos computacionales distribuidos. En ecosistemas fundamentados en microservicios y entor-

nos contenerizados con plataformas como Docker, así como en despliegues sobre infraestructuras de nube de alta disponibilidad (tales como Google Cloud Platform y DigitalOcean), PSO ejecuta un balanceo de carga algorítmico y una programación de tareas (*task scheduling*) sumamente eficientes [1, 3, 21]. Esta adaptabilidad metaheurística agiliza severamente los flujos de procesamiento de datos al integrarse de manera nativa con arquitecturas *backend* robustas, controladas por eventos y no bloqueantes en Node.js, e interactuando de forma fluida con sistemas de bases de datos no relacionales de alta demanda como MongoDB. Al aplicar la búsqueda estocástica para la selección heurística de nodos y el enrutamiento inteligente de consultas transaccionales, el algoritmo logra minimizar el tiempo de finalización global (*makespan*) y maximizar la escalabilidad estructural de las bases de datos frente a picos masivos de peticiones concurrentes [1, 3, 36]. Finalmente, estas severas optimizaciones de latencia de red y enrutamiento en las capas profundas del *backend* impactan de manera directa y tangible en la eficiencia de los flujos de trabajo administrativos. La capacidad inherente de PSO para lograr la convergencia global, equilibrando dinámicamente la exploración divergente y la explotación intensiva en fracciones de segundo, garantiza que la inyección de datos hacia las interfaces de usuario se realice con una velocidad óptima [5, 13]. En el contexto del desarrollo de software, esto se traduce directamente en una reducción exponencial de los tiempos de respuesta del servidor y en un renderizado altamente eficiente en paneles de control web y *dashboards* administrativos. Consecuentemente, la actualización asíncrona de información hiper-crítica —tales como las métricas satelitales en vivo de una flota logística o el estado de consumo de la infraestructura en la nube— opera de manera transparente y en tiempo real, consolidando a la inteligencia de enjambre del PSO como un catalizador matemático indispensable para construir sistemas de información resilientes y de alto desempeño [1, 21].

Tabla 1.1: Resumen de la revisión de literatura: Evolución algorítmica, variantes y aplicaciones contemporáneas del Algoritmo de Optimización por Enjambre de Partículas (PSO) en el modelado y diseño de sistemas complejos en ingeniería.

Referencia	Variante de PSO	Problema de Ingeniería	Ventaja Competitiva
[1]	MALPSO (Modified PSO) e híbridos	Balanceo de carga algorítmico y programación de tareas en clústeres de servidores en la nube (Cloud Computing).	Acorta drásticamente el tiempo de finalización (<i>makespan</i>) y equilibra dinámicamente las cargas, optimizando la asignación de recursos virtuales.
[14]	OPSO (Orthogonal PSO)	Despacho Económico de Energía Térmica bajo restricciones no convexas (límites de rampa y zonas prohibidas).	Mitiga el colapso por "zigzagging" usando vectores de diagonalización ortogonal, asegurando convergencia global y reduciendo el costo total del sistema eléctrico.
[22]	SEPSO (Social Engineering PSO)	Diagnóstico inverso de daños estructurales (VBDI) basado en el análisis de variables de vibración mecánica.	Emplea estrategias elitistas y operadores probabilísticos de ataque social para esquivar óptimos locales en dominios topológicos sumamente fragmentados y ruidosos.
Continúa en la siguiente página...			

Tabla 1.1 – Continúa de la página anterior

Referencia	Variante de PSO	Problema de Ingeniería	Ventaja Competitiva
[9]	PSO-GWO (Híbrido)	Sintonización algorítmica de parámetros de controladores PID robustos en sistemas dinámicos no lineales.	Reduce a menos del 10 % las evaluaciones de la función de costo al compensar la pérdida de diversidad del PSO con la jerarquía estocástica de exploración del GWO.
[5]	VPPSO (Velocity Pausing PSO)	Diseño ingenieril integral de componentes sujetos a restricciones físicas (ej. deflexión en vigas y tensión en resortes).	Introduce una "pausa de velocidad" probabilística y topología de doble enjambre para estabilizar el equilibrio entre exploración y explotación en problemas de hiper-dimensionalidad.
[2]	TPOPSOGWO (Dos Fases + OBL)	Resolución de hiper-superficies geométricas en problemas de diseño industrial altamente restringidos matemáticamente.	Mejora radicalmente la heterogeneidad de la población al inyectar inicializaciones por Aprendizaje Basado en Oposición (OBL), acelerando la tasa de convergencia sin violar límites físicos.
[6]	PSO-HS (con Harmony Search) y EPSO	Análisis de Confiabilidad Estructural de Primer Orden (FORM) y búsqueda de puntos de falla más probables (MPP).	Elimina la dependencia de vectores de sensibilidad de métodos analíticos de gradiente, brindando invulnerabilidad ante funciones de rendimiento discretas de alta dimensión.
[37]	PSO Clásico (Optimización Bayesiana)	Determinación óptima de ganancias para controladores de modo deslizante (SMC) en manipuladores robóticos (2-DOF).	Encuentra compromisos excepcionales entre errores de estado estacionario y velocidad de respuesta a través de funciones de costo sustitutas (Surrogate Models), superando enfoques evolutivos estándar.
[19]	PSO con Mutación de Ruido Blanco (GWN)	Actualización dinámica de modelos de elementos finitos (FEA) de alta fidelidad para puentes atirantados a gran escala.	Inyecta ruido blanco gaussiano como mecanismo mutacional para provocar saltos estocásticos de fuga y evadir el estancamiento prematuro en sistemas de ecuaciones altamente acoplados.

1.5. Análisis de Complejidad Computacional

El análisis de la complejidad computacional del Algoritmo de Optimización por Enjambre de Partículas (PSO) resulta imperativo para comprender su aplicabilidad y escalabilidad en escenarios ingenieriles de alta exigencia. Fundamentado en la notación asintótica Big-O, el límite superior de crecimiento temporal del algoritmo clásico se define exhaustivamente mediante la ecuación $O(N \times I \times D)$, donde N representa el tamaño del enjambre (número de partículas activas), I equivale al límite de iteraciones máximas predefinidas para la convergencia, y D denota la dimensionalidad del hiperespacio de búsqueda [18, 30]. Desde una perspectiva analítica rigurosa, es vital discernir que el costo computacional principal de PSO no reside en la actualización cinemática matemática de los vectores de velocidad y posición en cada iteración —una operación algebraica de costo computacional relativamente trivial y estrictamente lineal de orden $O(N \times D)$ —, sino en la evaluación iterativa de la función objetivo o *función fitness* [18, 30]. A medida que la complejidad del modelo fenomenológico a optimizar aumenta (como en el análisis de elementos finitos o dinámicas de fluidos computacional), el tiempo de procesamiento consumido por el simulador subyacente para dictaminar la calidad de las soluciones eclipsa por completo la carga matemática propia del algoritmo estocástico [13, 30]. Este panorama algorítmico se torna considerablemente más denso al evaluar el costo computacional de las hibridaciones y variantes avanzadas. Si bien la integración de arquitecturas híbridas o modificadas es mandataria para mitigar deficiencias letales como el atrapamiento en óptimos locales, esto acarrea un ineludible compromiso (*Trade-off*) que incrementa significativamente la carga de procesamiento del sistema [1, 30]. Por ejemplo, el despliegue del PSO Multiobjetivo (MOPSO) añade una profunda capa de complejidad no lineal, usualmente de orden cuadrático o logarítmico, debido a la imperativa necesidad de contrastar, clasificar y ordenar topológicamente de manera incesante las soluciones no dominadas frente al resto de la población para mantener y depurar el repositorio externo del Frente de Pareto [3, 27]. Del mismo modo, hibridaciones sinérgicas profundas como la arquitectura PSO-GWO incrementan de manera sustancial la cantidad de cálculos estocásticos y evaluaciones por iteración, al requerir que la población (o sus sub-enjambres) se someta simultáneamente a la lógica jerárquica de exploración de los lobos grises y al esquema de explotación posicional basado en vectores de inercia del PSO [9]. A partir del precedente análisis de complejidad, se hace posible justificar y contrastar teóricamente la viabilidad de implementación del algoritmo. PSO y sus robustas variantes híbridas se consolidan como herramientas ideales y formidables bajo escenarios de *diseño offline*, la simulación de pre-lanzamiento, el diseño asistido por computadora (CAD) y el entrenamiento profundo de modelos matemáticos. En estos ecosistemas, tolerar una ejecución que demande minutos u horas es operacionalmente admisible en aras de alcanzar una sintonización de ganancia o un diseño geométrico óptimo global antes del despliegue en campo [9, 30]. Sin embargo, este mismo costo computacional transforma su aplicación en un desafío crítico e inabordable cuando se trata de inyectar la metaheurística dentro del lazo cerrado de sistemas de control dinámico en tiempo real, donde responder ante perturbaciones requiere estrictas latencias de resolución en el orden de los milisegundos [30, 33]. Para eludir estas barreras algorítmicas y mitigar los cuellos de botella en problemas de altísima complejidad y ultra-alta dimensionalidad, la ingeniería moderna ha trascendido la ejecución secuencial clásica. La vanguardia algorítmica recurre hoy a la paralelización masiva de las partículas del enjambre sustentándose en el paradigma analítico de "divide y vencerás" [1, 3]. Al independizar la trayectoria de cada individuo, la evaluación simultánea de la función *fitness* se delega a entornos de aceleración por hardware de alto desempeño, empleando infraestructuras distribuidas como clústeres de múltiples núcleos CPU en la nube o el procesamiento paralelo masivo provisto por la arquitectura de Unidades de Procesamiento Gráfico (GPUs, mediante tecnologías como CUDA), reduciendo de manera drástica y categórica los tiempos globales de ejecución para viabilizar diseños de una magnitud computacional sin precedentes [1, 3].

1.6. Conclusiones

A lo largo del presente trabajo, se ha evidenciado que el Algoritmo de Optimización por Enjambre de Partículas (PSO) se ha consolidado definitivamente como una herramienta matemática y computacional formidable para la resolución de problemas de ingeniería. La transición evolutiva desde su formulación clásica hacia arquitecturas híbridas y variantes algorítmicas de vanguardia ha marcado un hito en la superación de sus vulnerabilidades intrínsecas. Específicamente, desarrollos avanzados como el Algoritmo Crazy PSO con mutación adaptativa y las variantes cooperativas y adaptativas (denominadas en la literatura como ACPSO) han permitido mitigar con éxito sus limitaciones históricas, resolviendo de manera contundente el grave problema de la convergencia prematura en espacios de búsqueda altamente multidimensionales [1, 21, 39]. Estas adaptaciones estructurales dotan a la población de partículas de la diversidad genética y la inyección estocástica necesarias para evadir trampas de óptimos locales en topologías rugosas, garantizando el descubrimiento de soluciones globales [3, 10]. En virtud del análisis teórico y empírico expuesto, es posible dar una respuesta explícita y directa a la interrogante central que vertebra esta investigación: ¿Cómo optimiza PSO problemas complejos en ingeniería? PSO optimiza mediante la ejecución de un riguroso equilibrio dinámico estocástico entre la exploración global divergente del hiperespacio y la explotación local intensiva de las regiones prometedoras [1, 16, 18]. Esta homeostasis algorítmica se materializa al adaptarse estructuralmente —a través de topologías de vecindario sofisticadas y ajustes temporales del peso de inercia y coeficientes cognitivo-sociales— a las restricciones severas y a las profundas no linealidades propias de la ingeniería moderna [3, 13, 21]. Al independizarse por completo de los requerimientos de derivabilidad y fundamentar su marcha en lógicas de inteligencia colectiva, el enjambre asimila, mapea y decodifica las complejas interacciones de las variables de diseño de manera resiliente e iterativa [2, 8]. En conclusión, la vigencia y superioridad de PSO en el entorno académico e industrial contemporáneo resultan indiscutibles. Su extraordinaria flexibilidad para amalgamar sinergias con otros optimizadores metaheurísticos y técnicas de inteligencia artificial garantiza su competitividad sostenida frente a escenarios dinámicos, ruidosos o de gran escala. A medida que la disciplina ingenieril transita de manera ineludible hacia modelos físicos exponencialmente más intrincados, PSO trasciende su categoría de metaheurística estándar para establecerse como un motor algorítmico indispensable en la nueva era del diseño automatizado y la optimización integral de sistemas [1, 3, 21].

Referencias

- [1] L. Abualigah, “Particle swarm optimization: Advances, applications, and experimental insights,” *Computers, Materials and Continua*, vol. 82, pp. 1539–1592, 2 2025.
- [2] R. Katarya, U. Agrawal, and V. Rohatgi, “Optimizing constrained engineering problems using opposition based swarm algorithms,” in *Proceedings – 2021 3rd International Conference on Advances in Computing, Communication Control and Networking, ICAC3N 2021*, pp. 861–867, Institute of Electrical and Electronics Engineers Inc., 12 2021.
- [3] Y. Zhang, S. Wang, and G. Ji, “A comprehensive survey on particle swarm optimization algorithm and its applications,” *Mathematical Problems in Engineering*, vol. 2015, p. 931256, 1 2015.
- [4] M. Khorsand and Y. Tang, “Design functionally graded rotating disks under thermoelastic loads: Weight optimization,” *International Journal of Pressure Vessels and Piping*, vol. 161, pp. 33 – 40, 2018. Cited by: 40.
- [5] T. M. Shami, S. Mirjalili, Y. Al-Eryani, K. Daoudi, S. Izadi, and L. Abualigah, “Velocity pausing particle swarm optimization: a novel variant for global optimization,” *Neural Computing and Applications*, vol. 35, no. 12, pp. 9193 – 9223, 2023. Cited by: 138; All Open Access; Green Open Access; Hybrid Gold Open Access.
- [6] S.-P. Zhu, B. Keshtegar, M. E. A. Ben Seghier, E. Zio, and O. Taylan, “Hybrid and enhanced pso: Novel first order reliability method-based hybrid intelligent approaches,” *Computer Methods in Applied Mechanics and Engineering*, vol. 393, 2022. Cited by: 121.
- [7] Y. Shafahi and M. Bagherian, “A customized particle swarm method to solve highway alignment optimization problem,” *Computer-Aided Civil and Infrastructure Engineering*, vol. 28, no. 1, pp. 52 – 67, 2013. Cited by: 165.
- [8] S. Chowdhury, W. Tong, A. Messac, and J. Zhang, “A mixed-discrete particle swarm optimization algorithm with explicit diversity-preservation,” *Structural and Multidisciplinary Optimization*, vol. 47, no. 3, pp. 367 – 388, 2013. Cited by: 114.
- [9] R. Vrabel, “Hybrid particle swarm and grey wolf optimization for robust feedback control of nonlinear systems,” *Automation*, vol. 6, p. 89, 12 2025.
- [10] Z. Cui, X. Cai, J. Zeng, and G. Sun, “Particle swarm optimization with fss and rws for high dimensional functions,” *Applied Mathematics and Computation*, vol. 205, no. 1, pp. 98 – 108, 2008. Cited by: 51.
- [11] A. H. Gandomi, G. J. Yun, X.-S. Yang, and S. Talatahari, “Chaos-enhanced accelerated particle swarm optimization,” *Communications in Nonlinear Science and Numerical Simulation*, vol. 18, no. 2, pp. 327 – 340, 2013. Cited by: 371.

- [12] G. Li and H. Hu, “Risk design optimization using many-objective evolutionary algorithm with application to performance-based wind engineering of tall buildings,” *Structural Safety*, vol. 48, pp. 1 – 14, 2014. Cited by: 42.
- [13] J. Fan, J. Wang, and M. Han, “Cooperative coevolution for large-scale optimization based on kernel fuzzy clustering and variable trust region methods,” *IEEE Transactions on Fuzzy Systems*, vol. 22, no. 4, pp. 829 – 839, 2014. Cited by: 46.
- [14] L. T. Al Bahrani and J. C. Patra, “Orthogonal pso algorithm for economic dispatch of thermal generating units under various power constraints in smart power grid,” *Applied Soft Computing Journal*, vol. 58, pp. 401 – 426, 2017. Cited by: 40.
- [15] T. Huang and A. Sanagavarapu Mohan, “A microparticle swarm optimizer for the reconstruction of microwave images,” *IEEE Transactions on Antennas and Propagation*, vol. 55, no. 3 I, pp. 568 – 576, 2007. Cited by: 51.
- [16] A. Biswas, S. Dasgupta, S. Das, and A. Abraham, “Synergy of pso and bacterial foraging optimization - a comparative study on numerical benchmarks,” *Advances in Soft Computing*, vol. 44, pp. 255 – 263, 2007. Cited by: 189.
- [17] M. Gonabadi, N. H. Hunt, and F. Fallahtafti, “EMG-based simulation for optimization of human-in-the-loop control in simple robotic walking assistance,” *Journal of Sensor and Actuator Networks*, vol. 14, p. 113, 12 2025.
- [18] S. Duan, H. Luo, and H. Liu, “A multi-strategy seeker optimization algorithm for optimization constrained engineering problems,” *IEEE Access*, vol. 10, pp. 7165–7195, 1 2022.
- [19] Z. Xia, A. Li, J. Li, H. Shi, M. Duan, and G. Zhou, “Model updating of an existing bridge with high-dimensional variables using modified particle swarm optimization and ambient excitation data,” *Measurement: Journal of the International Measurement Confederation*, vol. 159, 2020. Cited by: 49.
- [20] C. Turkeri, S. Ekinici, G. Yuksek, and D. Li, “A modified enzyme action optimizer-based FOPID controller for temperature regulation of a nonlinear continuous stirred tank reactor,” *Fractal and Fractional*, vol. 9, p. 811, 12 2025.
- [21] T. M. Shami, A. A. El-Saleh, M. Alswaitti, Q. Al-Tashi, M. A. Summakieh, and S. Mirjalili, “Particle swarm optimization: A comprehensive survey,” *IEEE Access*, vol. 10, pp. 10031–10061, 1 2022.
- [22] N. F. Alkayem, M. Cao, L. Shen, R. Fu, and D. Šumarac, “The combined social engineering particle swarm optimization for real-world engineering problems: A case study of model-based structural health monitoring,” *Applied Soft Computing*, vol. 123, 2022. Cited by: 40.
- [23] Z. Wang, Y. Li, L. Wu, and Q. Guo, “A nonlinear adaptive weight-based mutated whale optimization algorithm and its application for solving engineering problems,” *IEEE Access*, vol. 12, pp. 40225–40254, 1 2024.
- [24] X. Zhao, Q. Ma, J. Li, Z. Wu, H. Lu, and Y. Xiong, “Optimization design of lazy-wave dynamic cable configuration based on machine learning,” *Journal of Marine Science and Engineering*, vol. 13, p. 873, 4 2025.
- [25] A. Gálvez and A. Iglesias, “Particle swarm optimization for non-uniform rational b-spline surface reconstruction from clouds of 3d data points,” *Information Sciences*, vol. 192, pp. 174 – 192, 2012. Cited by: 159.

- [26] K. Gopalakrishnan, “Neural network-swarm intelligence hybrid nonlinear optimization algorithm for pavement moduli back-calculation,” *Journal of Transportation Engineering*, vol. 136, no. 6, pp. 528 – 536, 2010. Cited by: 42.
- [27] M. Z. b. Mohd Zain, J. Kanesan, J. H. Chuah, S. Dhanapal, and G. Kendall, “A multi-objective particle swarm optimization algorithm based on dynamic boundary search for constrained optimization,” *Applied Soft Computing Journal*, vol. 70, pp. 680 – 700, 2018. Cited by: 109; All Open Access; Green Open Access.
- [28] S. Yao, D. Guo, Z. Sun, and G. Yang, “A modified multi-objective sorting particle swarm optimization and its application to the design of the nose shape of a high-speed train,” *Engineering Applications of Computational Fluid Mechanics*, vol. 9, no. 1, pp. 513 – 527, 2015. Cited by: 43; All Open Access; Gold Open Access; Green Open Access.
- [29] Z. Cheng, C. Zhuo, and Q. Zhu, “Attitude control for hovering rocket decoy based on PSO-optimized sliding mode controller,” *Journal of Physics: Conference Series*, vol. 3126, p. 012064, 10 2025.
- [30] M. A. Sadi, A. Jamali, M. A. Zulkiffi, M. N. Leman, S. Mohamaddan, and H. Hazmi, “Enhanced control strategies for lower limb rehabilitation robots: A comparative study of MRAC, PID-ZN, and MRAC-PSO controllers,” *Applied Bionics and Biomechanics*, vol. 2026, p. 8945626, 1 2026.
- [31] F. Sancho Caparrini, “Pso: Optimización por enjambres de partículas.” <https://www.cs.us.es/~fsancho/Blog/posts/PSO.md.html>, 11 2019. Consultado el 31 de mayo de 2026.
- [32] H. Dallaki, A. Sami, A. Hamzeh, and S. Hashemi, “Using feature selection for speed up hybrid pso/aco,” *JOURNAL OF COMPUTING*, vol. 3, pp. 2151–9617, 1 2011.
- [33] M. Sánchez, M. Duarte, L. Bárzaga, M. Orchard, and G. Ceballos, “Fractional gradient-based model reference adaptive control applied on an inverted pendulum-cart system,” *Fractal and Fractional*, vol. 9, p. 485, 7 2025.
- [34] N. Yasir, F. Mahmood, M. Siddeeq, and M. Jaffer, “Enhanced CNN hyperparameter tuning via swarm intelligence for soil type classification,” 8 2025.
- [35] S. M. Ebadi, E. Khamsehchi, and J. M. Kalatehno, “A comprehensive comparative analysis of particle swarm optimization and genetic algorithms in well acidizing optimization,” *Journal of Petroleum Exploration and Production Technology*, vol. 15, pp. 1–19, 3 2025.
- [36] I. N. Kassabalidis, M. A. El-Sharkawi, R. J. Marks II, L. S. Moulin, and A. P. A. Da Silva, “Dynamic security border identification using enhanced particle swarm optimization,” *IEEE Transactions on Power Systems*, vol. 17, no. 3, pp. 723 – 729, 2002. Cited by: 101.
- [37] C. Castañeda, “AI-based optimization of a neural discrete-time sliding mode controller via bayesian, particle swarm, and genetic algorithms,” *Robotics*, vol. 14, p. 128, 9 2025.
- [38] A. Karamolachab, S. A. Mehdizadeh, and Y. Ampatzidis, “Design, optimization, and field evaluation of an automatic steering system for agricultural tractors using metaheuristic PID tuning,” *Agriculture*, vol. 16, p. 1004, 5 2026.
- [39] S. Samal, S. K. Sarangi, and A. Sarangi, “Analysis of adaptive mutation in crazy particle swarm optimization,” in *2020 International Conference on Computational Intelligence for Smart Power System and Sustainable Energy (CISPSSE)*, pp. 1–5, IEEE, 7 2020.